

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ



دانشگاه صنعتی خواجه نصیرالدین طوسی
دانشکده مهندسی صنایع

توسعه مدل ارزشیابی سهام با استفاده از یادگیری ماشین

کورس ملاقدیری

استاد راهنما:

دکتر امیرعباس نجفی

استاد مشاور:

دکتر مجید میرزایی

پایان نامه برای دریافت مدرک کارشناسی ارشد

رشته مهندسی صنایع گرایش مهندسی مالی

تیر ۱۴۰۳

چکیده

بازار سهام به عنوان یکی از سیستم‌های بسیار پیچیده در نظر گرفته می‌شود که از اجزای زیادی تشکیل شده است و قیمت آن بدون داشتن الگوی مشخص بالا و پایین می‌رود. با افزایش بی‌وقفه ارزش بازار، معاملات سهام به مرکز سرمایه‌گذاری برای بسیاری از سرمایه‌گذاران مالی تبدیل شده است. بازار سهام یک محور کلیدی در هر اقتصاد در حال رشد و شکوفایی است و هر سرمایه‌گذاری در بازار، با هدف به حداکثر رساندن سود و به حداقل رساندن ریسک مرتبط است. بسیاری از تحلیلگران و محققان ابزارها و روش‌هایی را توسعه داده‌اند که حرکت قیمت و ارزش سهام را پیش‌بینی می‌کند و به سرمایه‌گذاران در تصمیم‌گیری صحیح کمک می‌نماید. مدل‌های معاملاتی پیشرفته، محققان را قادر می‌سازد تا با استفاده از داده‌های پلتفرم‌های اجتماعی، بازار را پیش‌بینی کنند. استفاده از روش‌های پیشرفته، دقت پیش‌بینی را بسیار افزایش داده است. در همین حال، تحلیل و پیش‌بینی بازارهای سهام به دلیل وجود داده‌های پویا، نامنظم و آشفته همچنان یکی از چالش‌برانگیزترین حوزه‌های مطالعاتی است. هدف پژوهش حاضر ارائه مدلی است که بتواند ارزش سهام را پیش‌بینی نماید. به این منظور از مدل CNN-GRU برای پیش‌بینی ارزش سهام ده شرکت استفاده شده است. نتایج این پژوهش برای سیاست‌گذاران بازار مالی به عنوان شاخصی مفید است که از آن می‌توانند برای بهبود پیش‌بینی خود استفاده کنند.

کلمات کلیدی: یادگیری عمیق، شبکه عصبی پیچشی، واحد بازگشتی دروازه‌ای، CNN-GRU، پیش‌بینی ارزش سهام.

فهرست مطالب

فصل اول : مقدمه و کلیات تحقیق	1
1-1 مقدمه	2
2-1 بیان مسئله	4
3-1 ضرورت و اهمیت پژوهش	6
4-1 مرور کلی بر ادبیات موضوع	7
5-1 اهداف پژوهش	7
6-1 سوالات پژوهش	8
7-1 کاربران نتایج پژوهش	8
8-1 کاربردهای موضوع پژوهش	8
9-1 ساختار گزارش	8
10-1 جمع‌بندی	9
فصل دوم: مبانی نظری و مرور ادبیات	10
1-2 مقدمه	11
2-2 ارزش‌گذاری سهام	11
3-2 یادگیری عمیق	13

14	1-3-2 مدل پرسپترون چند لایه
15	2-3-2 شبکه عصبی پیچشی
16	3-3-2 شبکه عصبی بازگشتی
18	4-2 کارهای پیشین
18	1-4-2 رویکردهای سری زمانی
19	2-4-2 رویکردهای یادگیری ماشین
22	3-4-2 رویکردهای یادگیری عمیق
25	4-4-2 رویکردهای ترکیبی
32	5-2 نتیجه گیری
35	فصل سوم : روش شناسی تحقیق
36	1-3 مقدمه
36	2-3 روش پیشنهادی
37	3-3 مجموعه داده
39	4-3 پیش پردازش
39	1-4-3 رسیدگی به داده های گمشده
40	2-4-3 نرمال سازی حداقل - حداکثر
40	5-3 مدل پیاده سازی

40 مدل CNN 1-5-3
42 مدل GRU 2-5-3
43 CNN-GRU مدل تشکیل دهنده 3-5-3 لایه های
44 معیارهای ارزیابی 6-3
44 میانگین ریشه مربعات خطا 1-6-3
45 میانگین مربعات خطا 2-6-3
45 میانگین خطای مطلق 3-6-3
45 معیار امتیاز R^2 4-6-3
45 معیار میانگین درصد خطای مطلق 5-6-3
46 معیار میانگین درصد خطای مطلق نرمال شده 6-6-3
46 نتیجه گیری 7-3
47 فصل چهارم : پیاده سازی و نتایج پژوهش
48 2-4 مجموعه داده و پیش پردازش داده ها
49 3-4 پیاده سازی مدل
50 4-4 ارزیابی نتایج
50 1-4-4 سهام تیپیکو
51 2-4-4 خبهمن

52 3-4-4 خودرو
54 4-4-4 شاراک
55 5-4-4 شبهرن
56 6-4-4 شخارک
57 7-4-4 فارس
59 8-4-4 کگل
60 9-4-4 همراه
61 10-4-4 ومعادن
62 5-4 مقایسه نتایج
64 6-4 نتیجه گیری
65 فصل پنجم: نتیجه گیری و پیشنهادات برای تحقیقات آتی
66 1-5 نتیجه گیری
67 2-5 کارهای آینده
68 منابع

فهرست جدول‌ها

- جدول 2-1 : مقایسه مطالعات انجام شده در حوزه پیش‌بینی قیمت سهام ----- 32
- جدول 3-1: ویژگی‌های موجود در مجموعه داده‌ها ----- 38
- جدول 4-1: هایپرپارامترهای انتخاب شده در پیاده‌سازی مدل ----- 49
- جدول 4-2 : نتایج ارزیابی مدل برای سهام تیپیکو ----- 51
- جدول 4-3: نتایج ارزیابی مدل برای سهام خبهن ----- 52
- جدول 4-4: نتایج ارزیابی مدل برای سهام خودرو ----- 53
- جدول 4-5: نتایج ارزیابی مدل برای سهام شاراک ----- 54
- جدول 4-6 : نتایج ارزیابی مدل برای سهام شبهرن ----- 56
- جدول 4-7: نتایج ارزیابی مدل برای سهام شخارک ----- 57
- جدول 4-8: نتایج ارزیابی مدل برای سهام فارس ----- 58
- جدول 4-9: نتایج ارزیابی مدل برای سهام کگل ----- 59
- جدول 4-10: نتایج ارزیابی مدل برای سهام همراه ----- 61
- جدول 4-11: نتایج ارزیابی مدل برای سهام ومعدن ----- 62
- جدول 4-12: نتایج ارزیابی مدل CNN-GRU برای همه سهام بررسی شده ----- 63

فهرست شکل‌ها

- شکل 2-1: ساختار یک شبکه عصبی پرسپترون چند لایه (فغفوری و فریش، 2011) ----- 15
- شکل 2-2: ساختار شبکه عصبی پیچشی (سون و اولاوونمی آساکه، 2024) ----- 16
- شکل 2-3: ساختار شبکه عصبی بازگشتی (لای و همکاران، 2019) ----- 17
- شکل 2-4: مدل KNN بهبود یافته (یانینگ، 2020). ----- 19
- شکل 2-5: ساختار مقایسه‌ای پیشنهاد شده برای پیش‌بینی شاخص LQ45 (سیوکور و استیوان، 2021) -- 21
- شکل 2-6: ساختار مدل Bi-LSTM (هان و فو، 2023) ----- 23
- شکل 2-7: نحوه عملکرد مدل شبکه عصبی متشکل از 4 لایه LSTM (سالمی متقی و حقیر چهرقانی، 2023) ----- 24
- شکل 2-8: ساختار مدل CNN با داده‌های ورودی تک متغیره یک هفته گذشته (سن، مهتاب و ناث، 2023) ----- 26
- شکل 2-9: ساختار مدل CNN با داده‌های ورودی تک متغیره در دو هفته گذشته (سن، مهتاب و ناث، 2023) ----- 26
- شکل 2-10: ساختار مدل مبتنی بر XLNET و BiLSTM (لی و هو، 2024) ----- 27
- شکل 2-11: لایه‌های استفاده شده در مدل LSTM (چترجی و همکاران، 2021) ----- 29
- شکل 2-12: ساختار و نحوه اجرای مدل SACLSTM (وو و همکاران، 2023) ----- 30
- شکل 2-13: ساختار مدل CNN-LSTM (سون و اولاوونمی آساکه، 2024) ----- 31
- شکل 2-14: ساختار مدل CNN-BiLSTM (سون و اولاوونمی آساکه، 2024) ----- 32
- شکل 3-1: روش پیشنهادی ----- 37
- شکل 3-2: ساختار یک مدل CNN (سیت و همکاران، 2020) ----- 41

- شکل 3-3: ساختار مدل GRU (لی و همکاران، 2020) ----- 43
- شکل 3-4: لایه‌های مدل CNN-GRU ----- 44
- شکل 4-1: بخشی از مجموعه داده ----- 48
- شکل 4-2: نمودار پیش‌بینی ارزش سهام تیپیکو ----- 50
- شکل 4-3: نمودار پیش‌بینی ارزش سهام خبهن ----- 51
- شکل 4-4: نمودار پیش‌بینی ارزش سهام خودرو ----- 53
- شکل 4-5: نمودار پیش‌بینی ارزش سهام شاراک ----- 54
- شکل 4-6: پیش‌بینی ارزش سهام شبهرن ----- 55
- شکل 4-7: نمودار پیش‌بینی ارزش سهام شخارک ----- 56
- شکل 4-8: نمودار پیش‌بینی ارزش سهام فارس ----- 58
- شکل 4-9: نمودار پیش‌بینی ارزش سهام کگل ----- 59
- شکل 4-10: نمودار پیش‌بینی ارزش سهام همراه ----- 60
- شکل 4-11: نمودار پیش‌بینی ارزش سهام ومعادن ----- 61

فصل اول

مقدمه و کلیات تحقیق

1-1 مقدمه

مسئله ارزشیابی سهام همیشه یکی از موضوعاتی است که به طور گسترده مورد مطالعه قرار گرفته است و شامل یک رویکرد جامع است که بر تحلیل تاریخچه قیمت‌ها، حرکات قیمت یا روندها برای پیش‌بینی قیمت‌های آتی تمرکز دارد (سونکاوده^۱ و همکاران، 2023). مدل‌ها و پیش‌بینی‌های متعددی برای پیش‌بینی ارزش سهام پیشنهاد شده‌اند. از آنجا که قیمت‌های سهام حرکتی تصادفی^۲ دارند (عبیدت^۳، 2021)، محققان ادعا می‌کنند که اطلاعات مالی شرکت به‌طور سیستماتیک در قیمت فعلی منعکس خواهد شد. بر اساس فرضیه بازار کارآمد^۴ (EMH)، بازار کارآمد، بازاری است که قیمت‌ها همیشه تمام اطلاعات موجود را منعکس می‌کنند (گوا^۵ و همکاران، 2020). کارایی بازار به سه شکل ضعیف، نیمه قوی و قوی طبقه‌بندی می‌شود. در عمل، سرمایه‌گذاران و متخصصان مالی معمولاً از تحلیل تکنیکال و تحلیل بنیادی برای پیش‌بینی قیمت سهام یا تصمیم‌گیری معاملات استفاده می‌کنند (بیاز^۶ و همکاران، 2018). تحلیل بنیادی، مطالعه عوامل مؤثر بر عرضه و تقاضا است. داده‌های مهم مورد استفاده برای تحلیل بنیادی شامل داده‌های شرکت مانند گزارش‌های مالی، گزارش‌های سالانه شرکت و ترازنامه هستند (نتی^۷ و همکاران، 2020).

¹ Sonkavde

² Random walk

³ Obeidat

⁴ Efficient market hypothesis

⁵ Guo

⁶ Beyaz

⁷ Nti

یک روش پرکاربرد، تحلیل سری زمانی است که شامل روش‌هایی برای تحلیل داده‌های سری زمانی برای استخراج ویژگی‌ها و ویژگی‌های آماری معنی دار در داده‌هاست (دودک^۱، 2023). روش میانگین متحرک یکپارچه اتورگرسیو^۲ (ARIMA) یک روش آماری پرکاربرد برای تحلیل و پیش‌بینی داده‌های سری زمانی است (بابو و ردی^۳، 2014). در حالی که روش ARIMA سودمندی خود را در ثبت روندهای کوتاه مدت تا میان مدت قیمت نشان داده است، مدیریت پویایی‌های پیچیده و الگوهای غیرخطی اغلب در بازارهای سهام مشاهده می‌شود. برای رفع کاستی‌های سیستم‌های پیش‌بینی قیمت سهام مرسوم مبتنی بر رویکردهای ARIMA، یک رویکرد مبتنی بر یادگیری با استفاده از روش‌های یادگیری ماشین و یادگیری عمیق معرفی شده است. پیچیدگی‌های بازارهای مالی، با تعاملات پویا بین عناصر مختلف که بر قیمت سهام تأثیر می‌گذارند، مشخص می‌شود (مینتاریا^۴ و همکاران، 2023).

اخیراً از رویکردهای یادگیری عمیق برای پیش‌بینی قیمت سهام استفاده شده است. مدل‌های یادگیری عمیق می‌توانند وابستگی‌های زمانی پیچیده و الگوهای غیرخطی را که در حرکات قیمت سهام رایج هستند، ثبت کنند. مدل‌های مدرن یادگیری عمیق از تقریب یک تابع پیوسته استفاده می‌کنند و داده‌ها را با مفروضات کمتر تطبیق می‌دهند و در نتیجه به دقت و کارایی بالاتری دست می‌یابند (رضایی^۵ و همکاران، 2021).

به این منظور مطالعه حاضر از یک روش یادگیری عمیق مبتنی بر CNN-GRU برای پیش‌بینی ارزش سهام استفاده کرده است.

¹ Dudek

² Autoregressive integrated moving average

³ Babu & Reddy

⁴ Mintarya

⁵ Rezaei

1-2 بیان مسئله

پیش‌بینی ارزش سهام به دلیل عوامل بی‌شمار مؤثر بر پویایی بازار، کار پیچیده‌ای است که چالش‌های متعددی را به همراه دارد. یکی از چالش‌های مهم مدیریت نوین بازار است، زیرا قیمت‌ها تحت تأثیر اطلاعات مرتبط و داده‌های نامربوط یا تصادفی قرار می‌گیرند و تمایز بین اطلاعات تأثیرگذار و غیر تأثیرگذار را پیچیده می‌کند. دقت پیش‌بینی‌ها نیز بر کیفیت و کامل بودن داده‌ها متکی است، زیرا مدیریت داده‌های از دست رفته و داده‌های نادرست چالش‌های دائمی را ایجاد می‌کند. چالش‌های موجود در پیش‌بینی قیمت سهام، کاوش روش‌ها و رویکردهای جدید را تسریع کرده‌اند. این رویکردها همگی با هدف افزایش دقت و قابلیت اطمینان پیش‌بینی‌کننده هستند (ووونگ¹ و همکاران، 2024). پیش‌بینی بازار سهام یک کار پیچیده است و عوامل زیادی بر بازار تأثیر می‌گذارند. بنابراین، سرمایه‌گذاران قبل از سرمایه‌گذاری در سهام، دو نوع تحلیل را انجام می‌دهند. اول تحلیل بنیادی است. به‌عنوان مثال، سرمایه‌گذاران به ارزش ذاتی سهام، عملکرد صنعت، اقتصاد و موارد دیگر نگاه می‌کنند. دوم، در تحلیل تکنیکال، سرمایه‌گذاران به ارزش‌گذاری سهام و آمار تولید شده توسط فعالیت بازار، مانند قیمت‌ها و حجم‌های گذشته نگاه می‌کنند (پاتل² و همکاران، 2015).

امروزه با پیشرفت‌های فناوری، پیش‌بینی بازار سهام با استفاده از روش‌های بسیاری قابل انجام است (بابو و ردی، 2014). با پیشرفت تکنولوژی، الگوریتم‌های زیادی برای پیش‌بینی بازار سهام، مانند رگرسیون کلاسیک، استفاده شده است (مینتاریا و همکاران، 2023). روش‌های پیش‌بینی سری‌های زمانی آماری مرسوم، مانند ARIMA و انواع آن نیز به دلیل سطح کارایی آنها، بسیار مورد استفاده قرار می‌گیرند. مدل ARIMA برای داده‌های

¹ Vuong

² Patel

غیرخطی و غیر ثابت نامناسب است و کاربرد آن‌ها را محدود می‌کند؛ زیرا سری‌های زمانی مالی اغلب رفتارهای غیرخطی را نشان می‌دهند (پراساد^۱ و همکاران، 2022).

یادگیری ماشین می‌تواند روابط غیرخطی را در قیمت سهام تشخیص دهد و مدل کند که چالش‌هایی را برای روش‌های ARIMA ایجاد می‌کند. هر مدل نقاط قوت خود را در پیش بینی قیمت سهام دارد (یانینگ^۲، 2020). با این حال، توجه به این نکته مهم است که به دلیل پیچیدگی برخی از مدل‌های یادگیری ماشین، آنها ممکن است نتوانند داده‌های آموزشی را به خوبی به موارد جدید تعمیم دهند (چن^۳ و همکاران، 2021). مدل‌های یادگیری ماشین می‌توانند به نويز در داده‌ها بسیار حساس باشند که منجر به پیش‌بینی‌های نادرست می‌شود. آموزش و بهینه‌سازی مدل‌های یادگیری ماشین می‌تواند از نظر محاسباتی فشرده باشد و به منابع و زمان قابل توجهی به‌ویژه برای کلان داده‌ها نیاز دارد (مالاگرینو^۴ و همکاران، 2018).

مدل‌های یادگیری عمیق توانایی خود را در پیش‌بینی قیمت سهام با دقت بالا نشان داده‌اند و اغلب بهتر از مدل‌های مرسوم عمل می‌کنند. تطبیق‌پذیری^۵ آنها را قادر می‌سازد تا انواع داده‌ها و ساختارهای مختلف را مدیریت کنند و از مجموعه‌های متغیر متنوع از بازارهای مختلف استفاده کنند (روف^۶ و همکاران، 2021). علاوه بر این، آنها انعطاف‌پذیری^۷ را در کاوش داده‌های سری زمانی با طول‌های مختلف فراهم می‌کنند که به‌طور ویژه برای سهام‌هایی با تاریخچه معاملاتی متناقض سودمند است (حسین زاده و هراتی زاده^۸، 2019). با این حال، مدل‌های یادگیری عمیق به قدرت محاسباتی و منابع قابل توجهی برای آموزش نیاز دارند که ممکن است برای همه قابل دسترسی نباشد. داده‌های ناکافی می‌تواند عملکرد آنها را کاهش دهد. پیچیدگی مدل‌های یادگیری

¹ Prasad

² Yunneng

³ Chen

⁴ Malagrino

⁵ Versatility

⁶ Rouf

⁷ Flexibility

⁸ Hoseinzade & Haratizadeh

عمیق می‌تواند منجر به بیش‌برازش^۱ شود، به‌ویژه زمانی که مدل نسبت به سادگی کار یا حجم داده‌های موجود بسیار پیچیده باشد. برخی از مسائل، مانند مسئله ناپدید شدن گرادیان^۲ در شبکه‌های عصبی بازگشتی^۳ (RNN)، استفاده از انواع پیشرفته‌تر را ضروری می‌کند و به این ترتیب پیچیدگی توسعه و پیاده‌سازی مدل را افزایش می‌دهد (لیو^۴ و همکاران، 2022؛ خو^۵ و همکاران، 2020).

1-3 ضرورت و اهمیت پژوهش

درک حرکات بازار سهام بسیار مهم است؛ زیرا این بازارها قدرت اقتصادی و سلامت مالی یک کشور را منعکس می‌کنند. رفتار بازار متأثر از عوامل بی‌شماری مانند پویایی تجارت بین‌الملل، عملکرد اقتصادی داخلی، رویدادهای جهانی، اعلامیه‌های مالی دولت و تغییر سیاست بانک مرکزی است. رفتار بازار یک قلمرو پیچیده و بی‌ثبات است که در آن سرمایه‌گذاری‌ها غیرقابل پیش‌بینی هستند (سون و اولاونمی آساکه^۶، 2024). علاوه بر این، پیش‌بینی دقیق قیمت سهام برای سرمایه‌گذاران نیز بسیار مهم است، زیرا بینش‌های ارزشمندی را در مورد سلامت مالی و چشم انداز رشد یک شرکت ارائه می‌دهد. با این اطلاعات، سرمایه‌گذاران می‌توانند تصمیمات آگاهانه بگیرند، ریسک‌ها را کاهش دهند و در فرصت‌های سودآور بازار سرمایه‌گذاری کنند. در نتیجه، تحقیقات گسترده‌ای به توسعه روش‌های پیش‌بینی مؤثر با استفاده از مدل‌های مختلف ریاضی و روش‌های یادگیری ماشین و یادگیری عمیق اختصاص یافته است (پاتل^۷ و همکاران، 2024).

¹ Overfitting

² Vanishing gradient problem

³ Recurrent neural network

⁴ Liu

⁵ Xu

⁶ Seun & Olawunmi Asake

⁷ Patel

1-4 مرور کلی بر ادبیات موضوع

اخیراً روش‌های یادگیری عمیق در پیش‌بینی و ارزش‌گذاری بازار سهام توجه پژوهشگران را به خود جلب کرده است.

در مطالعه (گریتسما و لو^۱، 2020)، از یک رویکرد یادگیری ماشین مبتنی بر درخت تصمیم برای ارزش‌گذاری نسبی استفاده می‌شود. ارزش سهام با استفاده از ضریب بازار به دفتر، ارزش شرکت به دارایی و ارزش شرکت به فروش انجام می‌شود. مدل‌های یادگیری ماشین خطاهای ارزش‌گذاری مطلق میانه را به نسبت مدل‌های سنتی، بسته به چندین مورد استفاده شده، حداقل 5.6 تا 31.4 درصد کاهش می‌دهند.

در مطالعه (ژانگ^۲ و همکاران، 2023)، یک الگوریتم تکامل دیفرانسیل یکپارچه و طرح روش تخمین لحظه تطبیقی^۳ (Adam-ENN) برای سرمایه‌گذاران VC در مراحل اولیه برای پیش‌بینی ارزش‌گذاری شرکت کارآفرینی پیشنهاد شده است. طبق نتایج گزارش شده، روش یادگیری ماشین پیشنهادی از روش‌های پایه بهتر عمل می‌کند. همچنین تحلیل سهم ویژگی و نمودارهای وابستگی جزئی برای باز کردن جعبه سیاه روابط بین ارزش‌گذاری شرکت کارآفرینی و ویژگی‌های آن انجام شده است. نتایج نشان می‌دهد که تعداد سرمایه‌گذاران تأمین‌کننده مالی مهم‌ترین ویژگی است و سرمایه اجتماعی سرمایه‌گذاران نیز نقش مهمی در مدل پیش‌بینی دارد.

1-5 اهداف پژوهش

هدف این پژوهش، پیش‌بینی ارزش سهام است. برای این منظور از یک روش یادگیری عمیق یعنی روش CNN-GRU استفاده می‌شود و عملکرد این مدل در پیش‌بینی ارزش سهام سنجیده خواهد شد.

¹ Geertsema & Lu

² Zhang

³ Integrated differential evolution algorithm and adaptive moment estimation method scheme

1-6 سوالات پژوهش

این پژوهش با هدف پاسخ به سوالات زیر انجام شده است:

- چگونه می‌توان ارزش سهام را پیش‌بینی نمود؟
- چگونه می‌توان با استفاده از روش‌های یادگیری عمیق ارزش سهام را مورد پیش‌بینی قرار داد؟
- چگونه مدل CNN-GRU این پیش‌بینی را می‌تواند انجام دهد؟

1-7 کاربران نتایج پژوهش

این پژوهش به سرمایه‌گذاران، مدیران شرکت‌ها، تحلیلگران و نهادهای مالی مانند بانک‌ها و بیمه‌ها برای تصمیم‌گیری در مورد سرمایه‌گذاری از طریق ارزش‌گذاری سهام کمک می‌کند.

1-8 کاربردهای موضوع پژوهش

ارزش‌گذاری سهام کاربردهای مختلفی دارد. این ارزش‌گذاری به سرمایه‌گذاران کمک می‌کند تا تصمیم درستی در مورد سهام و ارزیابی سهام خود اتخاذ کنند. همچنین امکان مقایسه ارزش سهام را در یک صنعت یا بازار می‌دهد و به مدیران شرکت‌ها نیز در ارزیابی عملکرد و ارزش شرکت کمک می‌کند. به این ترتیب شرکت‌ها در مورد نحوه تأمین مالی راحت‌تر تصمیم‌گیری خواهند کرد. علاوه بر این بانک‌ها، بیمه‌ها و سایر نهادهای مالی برای ارزیابی ریسک و بازده سرمایه‌گذاری از ارزش‌گذاری سهام استفاده می‌کنند.

1-9 ساختار گزارش

در فصل دوم مفاهیم پایه در حوزه پیش‌بینی قیمت سهام بررسی می‌شود. علاوه بر این در فصل دوم، به مطالعاتی که در این حوزه انجام شده، پرداخته می‌شود. در فصل سوم، روش پیشنهادی این پژوهش ارائه می‌گردد. فصل چهارم به بررسی جزئیات پیاده‌سازی روش پیشنهادی پرداخته است. در فصل پنجم و انتهای نیز

نتیجه‌گیری کلی از این پژوهش بیان می‌شود. همچنین به منظور انجام تحقیقات آتی در این حوزه، پیشنهاداتی ارائه خواهد شد.

10-1 جمع‌بندی

ارزش‌گذاری سهام یک فرآیند ضروری و حیاتی برای سرمایه‌گذاران، شرکت‌ها و بازار سرمایه است که به بهبود تصمیم‌گیری‌ها و افزایش کارایی بازار منجر می‌شود. ارزش‌گذاری سهام و پیش‌بینی قیمت سهام دو رویکرد مکمل هستند که به‌طور مشترک به سرمایه‌گذاران در تصمیم‌گیری‌های سرمایه‌گذاری کمک می‌کند. هدف این پژوهش ارائه مدلی است که بتواند ارزش سهام یک شرکت را در بورس پیش‌بینی نماید. به این منظور از یک روش ترکیبی مبتنی بر یادگیری عمیق استفاده شده است.

فصل دوم

مبانی نظری و مرور ادبیات

2-1 مقدمه

در فصل اول به بررسی مقدمات حوزه پیش‌بینی قیمت سهام پرداخته شد. فصل دوم مفاهیم پایه در این حوزه بیان می‌شود. این مفاهیم شامل آشنایی و معرفی یادگیری عمیق و مدل‌های آن است. همچنین تحقیقاتی که از مدل‌های یادگیری عمیق برای پیش‌بینی سهام استفاده کرده‌اند، در این فصل آورده می‌شود. این مطالعات با توجه به راه‌حلی که ارائه داده‌اند، در چند دسته قرار می‌گیرند. علاوه بر این، در انتهای فصل دوم این مطالعات با یکدیگر مورد مقایسه قرار گرفته‌اند.

2-2 ارزش‌گذاری سهام

ارزش‌گذاری سهام یکی از مهم‌ترین موضوعات در حوزه سرمایه‌گذاری است. هدف از ارزش‌گذاری سهام تعیین ارزش واقعی یک سهم و مقایسه آن با قیمت فعلی سهم در بازار است. این امر به سرمایه‌گذاران کمک می‌کند تا تصمیم‌گیری درستی در مورد خرید، فروش یا نگهداری یک سهم داشته باشند. روش‌های مختلفی برای ارزش‌گذاری سهام مانند تحلیل بنیادی، تحلیل تکنیکال، روش ارزش فعلی و روش ارزش‌گذاری نسبی وجود دارد (ژانگ¹ و همکاران، 2023). در ادامه این روش‌ها بررسی شده‌اند.

روش تحلیل بنیادی: در این روش، ویژگی‌های مالی و عملکرد شرکت مورد بررسی قرار می‌گیرد تا ارزش ذاتی سهم تعیین شود.

¹ Zhang

روش تحلیل تکنیکال: در این روش، الگوهای قیمتی و حجم معاملات سهم در گذشته مورد تحلیل قرار می‌گیرد تا روند آتی قیمت سهم پیش‌بینی شود.

روش ارزش فعلی: در روش ارزش فعلی^۱، ارزش سهام بر اساس ارزش فعلی جریان‌های نقدی آتی شرکت محاسبه می‌شود. برای این منظور، ابتدا جریان‌های نقدی آتی شرکت برآورد می‌شود. سپس با استفاده از نرخ تنزیل مناسب، ارزش فعلی این جریان‌های نقدی محاسبه می‌گردد. نرخ تنزیل معمولاً بر اساس هزینه سرمایه شرکت یا نرخ بازده مورد انتظار سرمایه‌گذاران تعیین می‌شود. این روش بر پیش‌بینی های آینده شرکت تأکید دارد و ارزش ذاتی سهام را نشان می‌دهد.

روش ارزش‌گذاری نسبی: در این روش، ارزش سهام با استفاده از ضرایب و نسبت‌های مالی مشابه در صنعت مورد ارزیابی قرار می‌گیرد. روش ضرایب قیمت^۲ یکی از روش‌های ارزش‌گذاری نسبی است. در این روش، ارزش سهام بر اساس مقایسه با سهام شرکت‌های مشابه محاسبه و معمولاً از ضرایبی مانند نسبت قیمت به سود^۳ (P/E)، نسبت قیمت به ارزش دفتری^۴ (P/B) و نسبت قیمت به فروش^۵ (P/S) استفاده می‌شود. این ضرایب با استفاده از اطلاعات مالی شرکت‌های مشابه محاسبه و سپس برای ارزیابی سهام شرکت مورد نظر به کار گرفته می‌شوند. این روش بر اساس مقایسه با سایر شرکت‌ها عمل می‌کند و نشان‌دهنده ارزش نسبی سهام است.

در این پژوهش از نسبت P/E که یکی از مهم‌ترین و پرکاربردترین نسبت‌های مالی در ارزش‌گذاری سهام است، استفاده شده است. نسبت P/E نشان‌دهنده ارزش بازار یک سهم نسبت به سود هر سهم است. به عبارت دیگر، این نسبت نشان می‌دهد سرمایه‌گذاران چقدر برای هر واحد سود شرکت حاضرند پرداخت کنند. نحوه محاسبه نسبت P/E مطابق با رابطه 1-2 است. نسبت P/E به سرمایه‌گذاران کمک می‌کند تا ارزش سهام را با سایر

¹ Discounted cash flow

² Price multiples

³ Price to earnings ratio

⁴ Price to book ratio

⁵ Price to sales ratio

شرکت‌های مشابه در یک صنعت مقایسه کنند و تصمیم‌گیری مناسبی در مورد خرید، فروش یا نگهداری سهام داشته باشند (داتا^۱ و همکاران، 2018).

$$\frac{P}{E} = \frac{\text{قیمت هر سهم}}{\text{سود هر سهم}} \quad (1-2)$$

اخیراً روش‌های یادگیری عمیق برای پیش‌بینی نسبت P/E مورد استفاده قرار گرفته‌اند. یادگیری عمیق زیرمجموعه‌ای از یادگیری ماشین است که قادر است الگوهای پیچیده‌تری را در داده‌ها شناسایی کند. طبق مطالعات انجام شده، روش‌های یادگیری عمیق در مقایسه با روش‌های مرسوم یادگیری ماشین، می‌توانند پیش‌بینی‌های دقیق‌تری از نسبت P/E ارائه دهند.

3-2 یادگیری عمیق

یادگیری عمیق، زیرمجموعه‌ای از یادگیری ماشین است. یک مدل یادگیری عمیق شبکه‌ای متشکل از نورون‌هایی است که چندین پارامتر و لایه بین ورودی و خروجی دارند. یادگیری عمیق از رویکرد معماری شبکه‌های عصبی پیروی می‌کند. یادگیری عمیق، یادگیری خودکار ویژگی‌ها و نمایش آنها را به صورت سلسله مراتبی در سطوح مختلف فراهم می‌نماید. این فرآیند قدرتمند یادگیری عمیق را در تقابل با روش‌های یادگیری ماشین مرسوم قرار می‌دهد (ژانگ و همکاران، 2018). به طور خلاصه، معماری کامل یادگیری عمیق برای فرآیند استخراج و تغییر ویژگی استفاده می‌شود. لایه‌های اولیه پردازش ساده داده‌های ورودی را انجام می‌دهند یا ویژگی‌های آسان را یاد می‌گیرند. سپس خروجی به لایه‌های بالایی می‌رود و یادگیری ویژگی‌های پیچیده

¹ Dutta

انجام می‌شود. بنابراین، یادگیری عمیق برای مقابله با داده‌های بزرگتر و پیچیدگی مناسب است (شارما^۱ و همکاران، 2021). در ادامه برخی از روش‌های یادگیری عمیق معرفی می‌شوند.

2-3-1 مدل پرسپترون چند لایه

معماری شبکه عصبی مصنوعی مبتنی بر اتصال لایه‌ها توسط گره‌هایی به نام نرون و همچنین نرون‌های بیولوژیکی مغز است (ایسر^۲، 2013a). هر مسیر سیگنالی را بین نرون‌ها به شیوه‌ای مشابه سیناپس‌ها ارسال می‌کند. مدل پرسپترون چند لایه^۳ (MLP)، به‌عنوان یک شبکه عصبی مصنوعی پیشخور^۴، شامل سه بخش اصلی لایه ورودی، یک یا چند لایه پنهان و یک لایه خروجی است. این لایه‌ها می‌توانند برای پیش‌بینی، دسته‌بندی، پردازش سیگنال و فیلتر کردن خطا استفاده شوند (ایسر، 2013). هر گره از یک تابع غیرخطی استفاده می‌کند. مدل پرسپترون چند لایه از الگوریتم یادگیری پس انتشار برای فرآیند آموزش استفاده می‌کند (گوندوشمیان^۵ و همکاران، 2019). شکل 1-2 معماری شبکه توسعه‌یافته را نشان می‌دهد.


¹ Sharma

² Ecer

³ Multilayer Perceptron

⁴ Feedforward artificial neural network

⁵ Gundoshmian



شکل ۱-۰: ساختار یک شبکه عصبی پرسپترون چند لایه (فغفوری و فریش^۱، ۲۰۱۱)

2-3-2 شبکه عصبی پیچشی

شبکه عصبی پیچشی، نوعی شبکه عصبی پیشخور است که به دلیل کارایی خود در حوزه‌های مختلف از جمله پردازش تصویر و زبان طبیعی شهرت یافته است. کاربرد آن در پیش‌بینی سری‌های زمانی به همان اندازه قابل توجه است، زیرا وابستگی‌ها و الگوهای زمانی را در داده‌های متوالی به درستی نشان می‌دهد (لکان^۲ و همکاران، ۱۹۹۸). معماری شبکه عصبی پیچشی از طراحی هوشمندانه‌ای برای کاهش پیچیدگی مدل و جلوگیری از بیش‌برازش استفاده می‌کند. این مزیت از طریق میدان‌های دریافتی محلی^۳، وزن‌های مشترک^۴ و لایه‌های ادغام^۵ به دست می‌آید که در مجموع کارایی فرآیند یادگیری را افزایش می‌دهند (کین^۶ و همکاران، ۲۰۱۸). در مرکز شبکه عصبی پیچشی، لایه‌های پیچش^۷ آن قرار دارد که در آن هسته‌های پیچش^۸ متعدد به داده‌های ورودی

^۱ Faghfour & Frish

^۲ LeCun

^۳ Local receptive fields

^۴ Shared weights

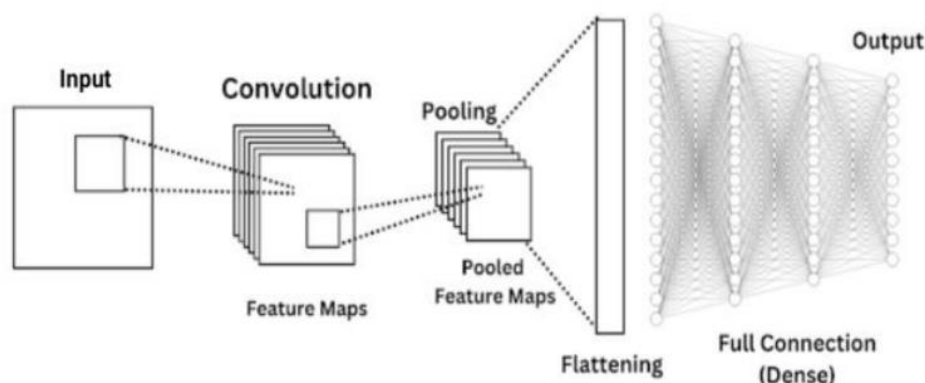
^۵ Pooling layers

^۶ Qin

^۷ Convolution layers

^۸ Convolution kernels

اعمال می‌شوند (سون و اولاوونمی آساکه، 2024). شکل 2-2 ساختار یک شبکه عصبی پیچشی را نشان می‌دهد.



شکل ۲-۰: ساختار شبکه عصبی پیچشی (سون و اولاوونمی آساکه، ۲۰۲۴)


3-3-2 شبکه عصبی بازگشتی

شبکه عصبی بازگشتی یک مدل یادگیری عمیق است که در سال 1990 توسط المان پیشنهاد شد (المان^۱، 1990). اساساً شبکه عصبی بازگشتی مشکل پردازش داده‌های توالی مانند متن، صدا و ویدیو را حل می‌کند. یک رابطه ترتیبی بین نمونه‌های این نوع داده وجود دارد و هر نمونه با نمونه قبلی خود مرتبط است. به عنوان مثال، در متن، یک کلمه با کلمه قبل از آن مرتبط است. در داده‌های هواشناسی دمای یک روز با دمای چند روز قبل ارتباط دارد. مجموعه‌ای از مشاهدات به عنوان دنباله‌ای تعریف می‌شود که از آن می‌توان توالی‌های متعددی را مشاهده کرد. این ویژگی الگوریتم شبکه عصبی بازگشتی، برای ویژگی‌های داده‌های سری زمانی در تحلیل سهام بسیار مناسب است. شکل 3-2 ساختار شبکه عصبی بازگشتی را نشان می‌دهد. طبق شکل 3-2، خروجی لایه

¹ Elman

پنهان در حافظه ذخیره می‌شود. حافظه را می‌توان به‌عنوان ورودی دیگری در نظر گرفت (لای^۱ و همکاران، 2019).

دلیل اصلی سختی آموزش شبکه عصبی بازگشتی، عبور از پارامتر لایه پنهان است. از آنجایی که انتشار خطا در شبکه عصبی بازگشتی کنترل نمی‌شود، مقدار موجود در لایه پنهان در طول انتشار رو به جلو و معکوس^۲ چند برابر می‌شود. مسئله از ناپدید شدن گرادیان^۳ این است که وقتی گرادیان کوچک است، به‌صورت تصاعدی افزایش می‌یابد و تقریباً هیچ تأثیری بر خروجی ندارد. مسئله انفجار گرادیان^۴ برعکس عمل می‌کند، اگر گرادیان بزرگ باشد، ضرب نمایی منجر به بزرگتر شدن گرادیان می‌شود. البته این مسئله در هر شبکه عصبی عمیق وجود دارد، اما به دلیل ساختار بازگشتی شبکه عصبی بازگشتی مشهود است (فیوک^۵ و همکاران، 2024).



شکل ۳-۰: ساختار شبکه عصبی بازگشتی (لای و همکاران، ۲۰۱۹)

¹ Lai

² Forward and reverse propagation

³ Problem of Gradient Vanishing

⁴ Gradient exploding problem

⁵ Phuoc

2-4 کارهای پیشین

مطالعات انجام شده در حوزه پیش‌بینی قیمت سهام در چهار دسته قرار می‌گیرند. در این بخش، این دسته‌ها به‌همراه مطالعات انجام شده در هریک، آورده شده است.

2-4-1 رویکردهای سری زمانی

تحلیل سری زمانی شامل روش‌هایی برای تحلیل داده‌های سری زمانی برای استخراج ویژگی‌های آماری معنی‌دار و ویژگی‌های داده‌هاست.

مطالعه (لاو و ساک^۱، 2023)، به مقایسه دقت پیش‌بینی دو مدل ARIMA و LSTM می‌پردازد. این مدل‌ها برای ده شاخص سهام مختلف، شامل صندوق‌های قابل معامله در بورس اعمال می‌شوند. پارامترها در هر دو مدل بهینه شده‌اند. طبق نتایج علیرغم اینکه ARIMA هنگام پیش‌بینی نقطه‌ای دقیق‌تر بود، اما مدل LSTM از نظر پیش‌بینی‌های بلندمدت به طور قابل توجهی بهتر عمل کرد. مشخص شد که پیش‌بینی‌های نقطه‌ای که توسط ARIMA انجام می‌شود، دقتی مشابه پیش‌بینی‌های بلندمدت انجام‌شده توسط LSTMs دارند.

مطالعه (خندروال و موهانتی^۲، 2021)، از مدل ARIMA برای پیش‌بینی قیمت سهام استفاده می‌کند. داده‌های مورد ارزیابی در این آزمایش، داده‌های سه سال از بورس ملی هند از 18 آوریل تا 21 فوریه هستند این مطالعه با استفاده از مدل ARIMA قیمت‌های آینده سهام را تا پایان 21 دسامبر پیش‌بینی می‌کند.


¹ Low & Sakk

² Khanderwal & Mohanty

2-4-2 رویکردهای یادگیری ماشین

روش‌های یادگیری ماشین می‌توانند اطلاعات غیرخطی را در داده‌های سری زمانی بدون تکیه بر داده‌های تصادفی یا دانش اقتصادی دریافت کنند. بنابراین، رویکردهای یادگیری ماشین را می‌توان برای ساخت سیستم‌های پیش‌بینی قیمت سهام با کارایی بالا بدون دانش تخصصی استفاده کرد.

مطالعه (یانینگ، 2020)، یک الگوریتم KNN بهبود یافته را پیشنهاد می‌کند. در این روش، اطلاعات قیمت سهام در N روز اول در یک نمونه ترکیب می‌شود، سپس برای یادگیری به مدل KNN داده می‌شود. آزمایش‌ها نشان می‌دهند که الگوریتم KNN بهبود یافته عملکرد پیش‌بینی بهتری نسبت به الگوریتم سنتی KNN دارد. شکل 2-4 ساختار مدل KNN بهبود یافته را نشان می‌دهد.



شکل ۴-۰: مدل KNN بهبود یافته (یانینگ، ۲۰۲۰).

در مطالعه (لین^۱ و همکاران، 2021)، یک روش مدل سازی اصلاح شده پیشنهاد شده است که هدف آن افزایش عملکرد روش KNN در پیش بینی سری های زمانی مالی است. ایده کلیدی، ترکیب روش تجزیه حالت تجربی گروه (EEMD) با روش k-نزدیکترین همسایه چندبعدی-پیش بینی سری زمانی با عدم تغییر^۲ (MKNN-TSPI) است. این ساختار جدید پیش بینی سری زمانی EEMD-MKNN-TSPI نامیده می شود. در این آزمایش نمونه ای از سری سهام دو بعدی ارائه شده است و روش اصلاح شده برای پیش بینی همزمان قیمت های باز و بسته شدن NAS، DJI، S&P 500، Russell 2000 و سایر سهام استفاده می شود. علاوه بر این، روش جدید با EEMD-MKNN و MKNN-TSPI مقایسه شده است. طبق نتایج مدل پیشنهادی بهتر از مدل EEMD-MKNN و MKNN-TSPI عمل می کند.

در مطالعه (سیوکور و استیوان^۳، 2021)، یک ساختار مقایسه ای پیشنهاد شده است که هدف آن ارزیابی عملکرد طیف وسیعی از مدل های دسته بندی و استفاده از آنها برای پیش بینی شاخص LQ45 است. شاخص LQ45، یک شاخص بورس اوراق بهادار در اندونزی و شامل 45 شرکت است که معیارهای خاصی را برای هدف قرار دادن سرمایه گذاران برای انتخاب سهام دارند. داده های این مطالعه شامل سطح معاملات و اندازه سرمایه است که از بورس اندونزی به دست آمده است. برای تحلیل داده ها از 10 مدل دسته بندی کننده استفاده شده است. این مدل ها رگرسیون لجستیک^۴ (LR)، بیزین ساده^۵ (NB)، K-نزدیک ترین همسایه، تحلیل خطی افتراقی^۶ (LDA)، K-Star، درخت رگرسیون و دسته بندی^۷ (CART)، C4.5، جنگل تصادفی^۸ (RF)، شبکه عصبی مصنوعی^۹ (ANN)، ماشین بردار پشتیبان^{۱۰} (SVM) هستند. نتایج نشان می دهد که الگوریتم جنگل تصادفی

¹ Lin

² Multidimensional k-nearest neighbors-time series prediction with invariance

³ Syukur & Istiawan

⁴ Logistic regression

⁵ Naive bayes

⁶ Linear discriminant analysis

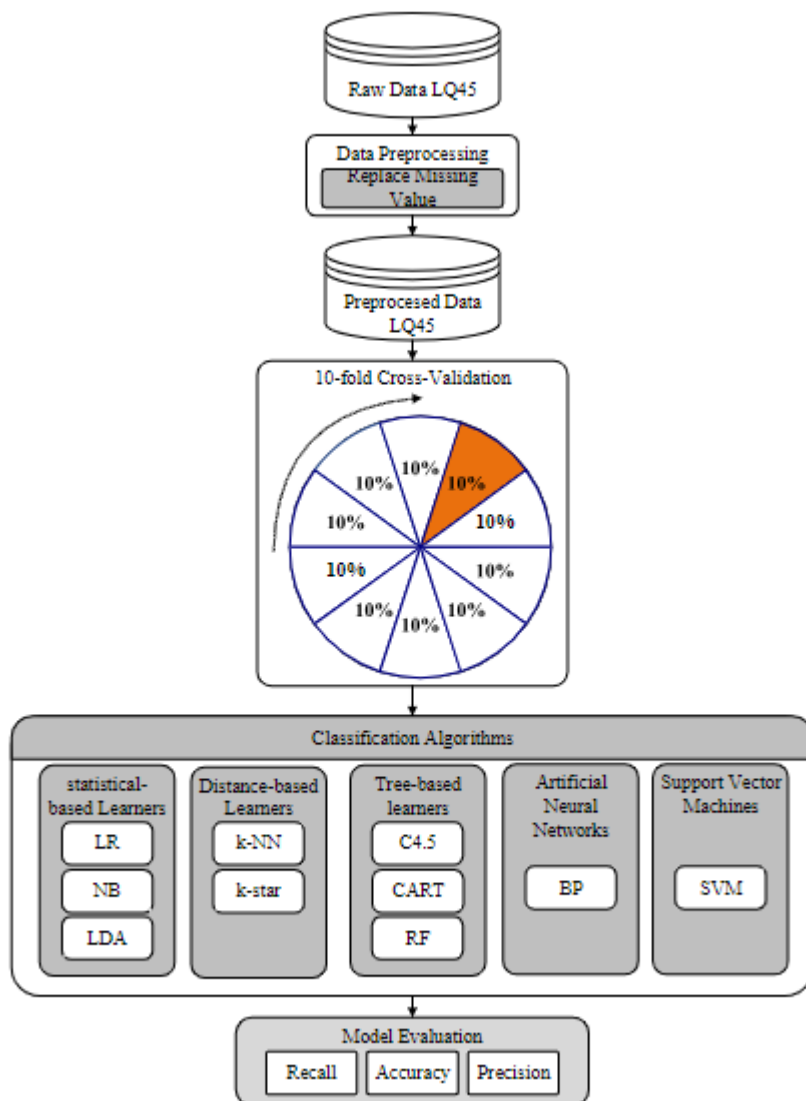
⁷ Classification and regression tree

⁸ Random forest

⁹ Artificial neural network

¹⁰ Support Vector Machine

بهترین عملکرد را برای پیش‌بینی شاخص LQ45 دارد. در حالی که درختان دسته‌بندی و رگرسیون، C4.5، ماشین بردار پشتیبان و الگوریتم‌های رگرسیون لجستیک نیز عملکرد خوبی دارند. علاوه بر این، به نظر می‌رسد مدل‌های مبتنی بر بیز ساده و تحلیل خطی افتراقی برای پیش‌بینی شاخص LQ45 عملکرد ضعیفی دارند. ساختار مدل مقایسه‌ای در شکل 2-5 نشان داده شده است.



شکل ۵-۰: ساختار مقایسه‌ای پیشنهاد شده برای پیش‌بینی شاخص LQ45 (سیوکور و استیوان، ۲۰۲۱)

2-4-3 رویکردهای یادگیری عمیق

رویکردهای یادگیری عمیق برای پیش بینی قیمت سهام اعمال شده است. مدل های یادگیری عمیق می توانند وابستگی های زمانی پیچیده و الگوهای غیرخطی را ضبط کنند که در حرکات قیمت سهام رایج هستند. مدل های مدرن مانند مدل CNN، مدل LSTM و مدل LSTM دو طرفه¹ (BILSTM) از تقریب یک تابع پیوسته استفاده و داده ها را با فرضیات کمتری سازگار می کنند. به این دلیل در حل مسائل غیرخطی به دقت و کارایی بالاتر می رسند.

مطالعه (گوش² و همکاران، 2022)، کارآمدی استفاده از شبکه های LSTM و RF را برای پیش بینی حرکات جهت دار قیمت سهام شاخص S&P 500 برای معاملات روزانه نشان دادند. داده های بررسی شده مربوط به ژانویه 1993 تا دسامبر 2018 هستند. در این مطالعه از ویژگی های مختلف و ترکیب آنها با یکدیگر برای پیش بینی استفاده شده است.

مطالعه (گوش و همکاران، 2024)، چهار معماری یادگیری عمیق یعنی پرسپترون چند لایه³ (MLP)، RNN، مدل LSTM و شبکه عصبی پیچشی را در پیش بینی قیمت سهام با استفاده از تاریخچه داده ها بررسی می کند. این مطالعه با تمرکز بر قیمت های بسته شدن روزانه از بورس ملی هند⁴ (NSE) و بورس اوراق بهادار نیویورک⁵ (NYSE)، شبکه عصبی را بر روی داده های NSE آموزش می دهد و آن را بر روی سهام NSE و NYSE آزمایش می کند. طبق نتایج مدل شبکه عصبی پیچشی نسبت به سایرین عملکرد بهتری دارد و علیرغم آموزش بر روی داده های NSE، این مدل با موفقیت قیمت سهام NYSE را پیش بینی کرده است.

¹ Bidirectional LSTM


² Ghosh

³ Multilayer perceptron

⁴ National stock exchange

⁵ New York stock exchange

در مطالعه (هان و فو^۱، ۲۰۲۳) یک مدل Bi-LSTM، برای پیش‌بینی قیمت آتی سهام بر اساس تاریخچه قیمت‌های آن پیشنهاد شده است. ارزیابی مدل Bi-LSTM با استفاده از تاریخچه داده‌های قیمت سهام شرکت اپل انجام می‌شود. شکل ۶-۲ ساختار مدل که در این مطالعه استفاده شده است را نشان می‌دهد.

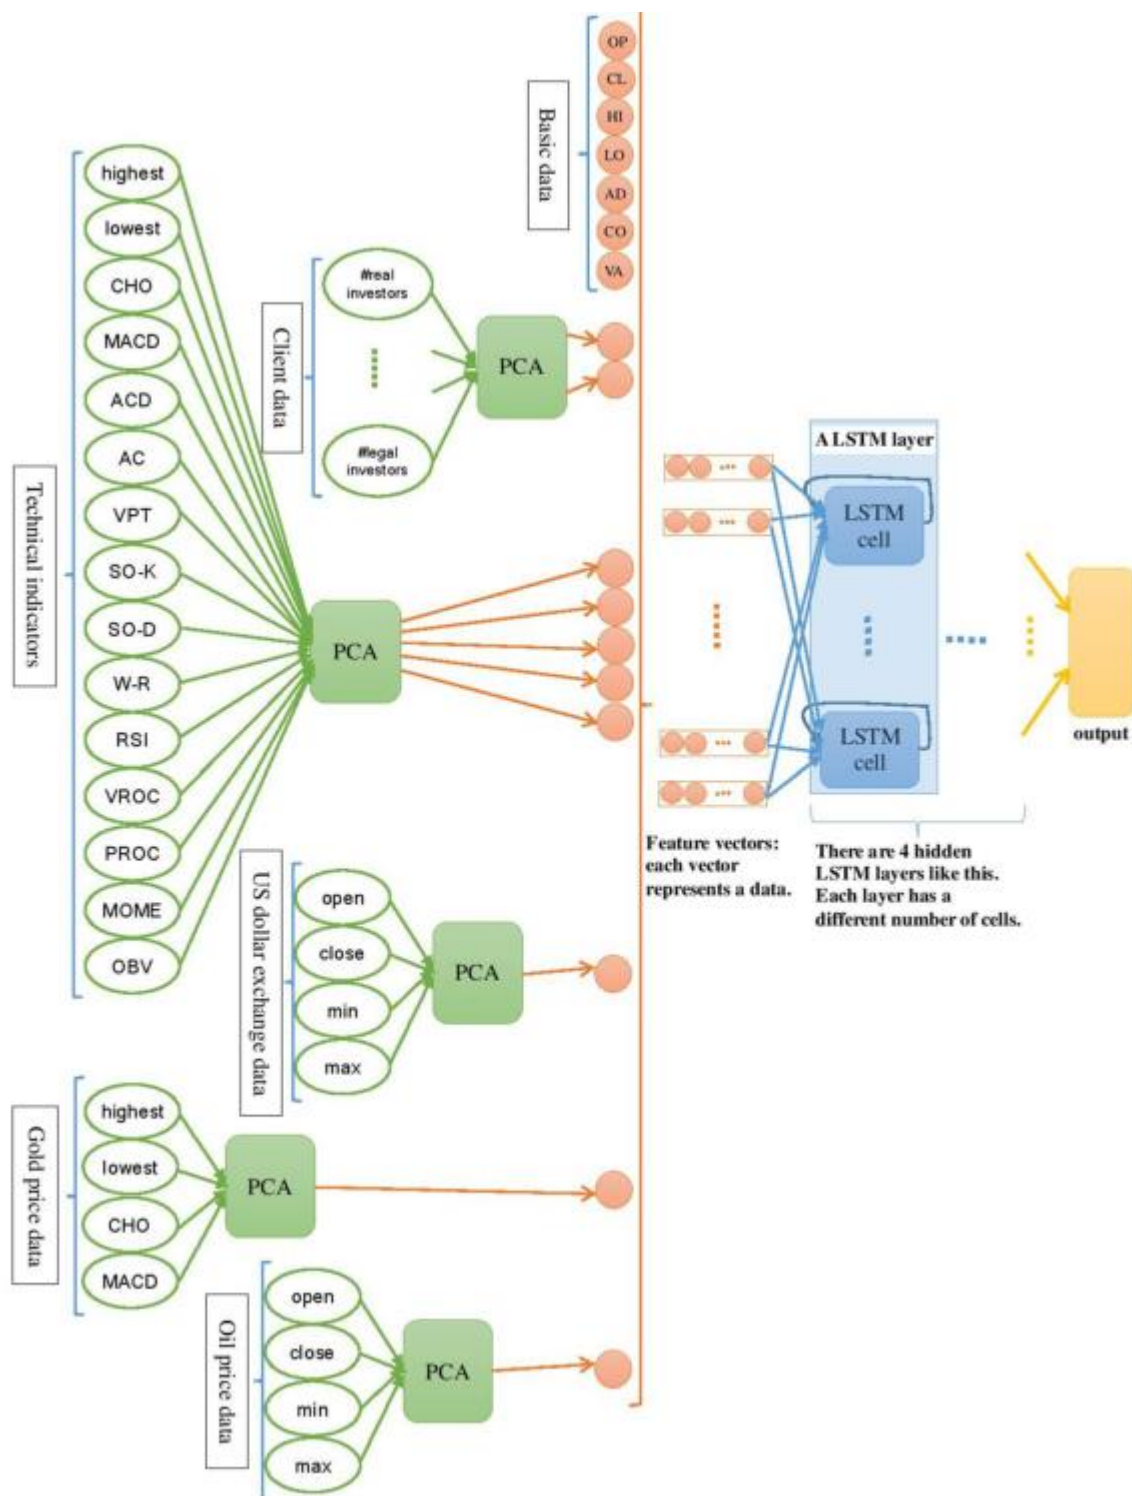


شکل ۶-۲: ساختار مدل Bi-LSTM (هان و فو، ۲۰۲۳)

در مطالعه (سالمی متقی و حقیر چهرقانی^۲، ۲۰۲۳) مدل شبکه عصبی LSTM متشکل از ۴ لایه پنهان پیشنهاد شده است و پیش‌بینی قیمت سهام پیشنهادی بر روی هشت مجموعه داده واقعی ارائه می‌شود. شکل ۷-۲ نحوه عملکرد این مدل را نشان می‌دهد. مطابق با این مدل، برای شاخص‌های فنی، برای داده‌های نرخ مبادله دلار آمریکا، داده‌های قیمت طلا، داده‌های قیمت نفت و داده‌های مشتری، یک PCA اعمال می‌گردد، تا ویژگی‌های مربوط به هریک استخراج گردد. سپس این بردارهای ویژگی استخراج شده به یک شبکه عصبی LSTM متشکل از ۴ لایه پنهان تغذیه می‌شوند.

¹ Han & Fu

² Salemi Mottaghi & Haghiri Chehrehgani



شکل 0-7: نحوه عملکرد مدل شبکه عصبی متشکل از 4 لایه LSTM (سالمی متقی و حقیر چهرقانی، ۲۰۲۳)

2-4-4 رویکردهای ترکیبی

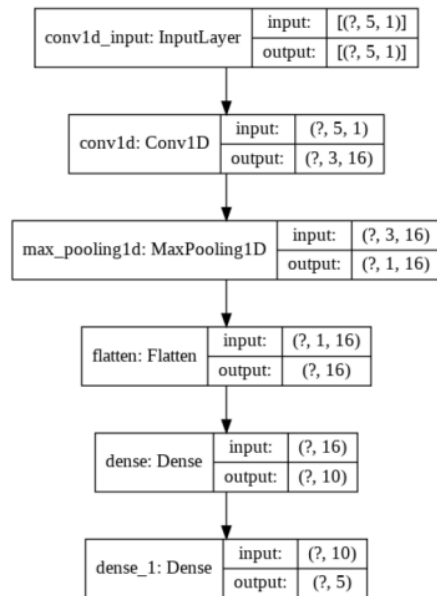
یک مدل ترکیبی برای پیش‌بینی قیمت سهام، به‌طور معمول روش‌های مدل‌سازی پیش‌بینی‌کننده‌های مختلف را برای افزایش دقت و قابلیت اطمینان پیش‌بینی قیمت سهام ادغام می‌کند.

در مطالعه (سن، مهتاب و ناث¹، 2023)، یک روش ترکیبی برای پیش‌بینی قیمت سهام با استفاده از پنج مدل رگرسیون مبتنی بر یادگیری عمیق پیشنهاد می‌شود. داده‌های استفاده شده در این آزمایش از یک دوره در 29 دسامبر 2014 تا 31 ژوئیه 2020، از شاخص Nifty 50 بورس ملی هند انتخاب شده است. مدل‌ها در معماری متفاوت هستند و داده‌های ورودی آنها نیز متفاوت است. پنج مدل استفاده شده،

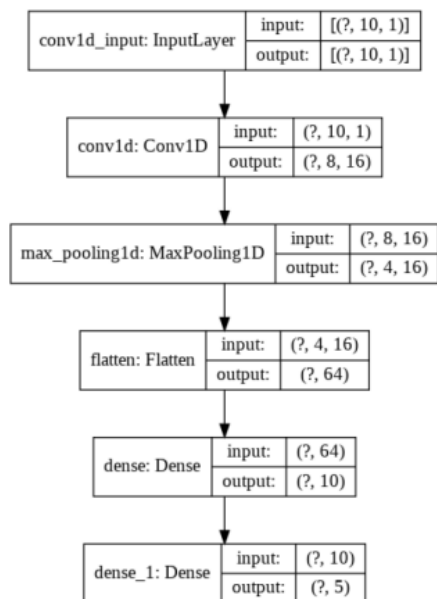
- i. مدل CNN با داده‌های ورودی تک متغیره یک هفته گذشته (شکل 2-8)،
- ii. مدل CNN با داده‌های ورودی تک متغیره در دو هفته گذشته (شکل 2-9)،
- iii. مدل Encoder-decoder LSTM با داده‌های تک متغیره دو هفته گذشته،
- iv. مدل Encoder-decoder CNN LSTM با داده‌های ورودی تک متغیره دو هفته گذشته و
- v. مدل Encoder-decoder Convolutional LSTM با داده‌های ورودی تک متغیره دو هفته گذشته

هستند. نتایج حاکی از آن است که مدل CNN که داده‌های یک هفته قبل را به‌عنوان ورودی دریافت می‌کند، سریعترین اجرا را دارد. از طرف دیگر، مدل Encoder-decoder Convolutional LSTM که از داده‌های دو هفته گذشته استفاده می‌کند، دقیق‌ترین پیش‌بینی را انجام داده است.

¹ Sen, Mehtab, & Nath

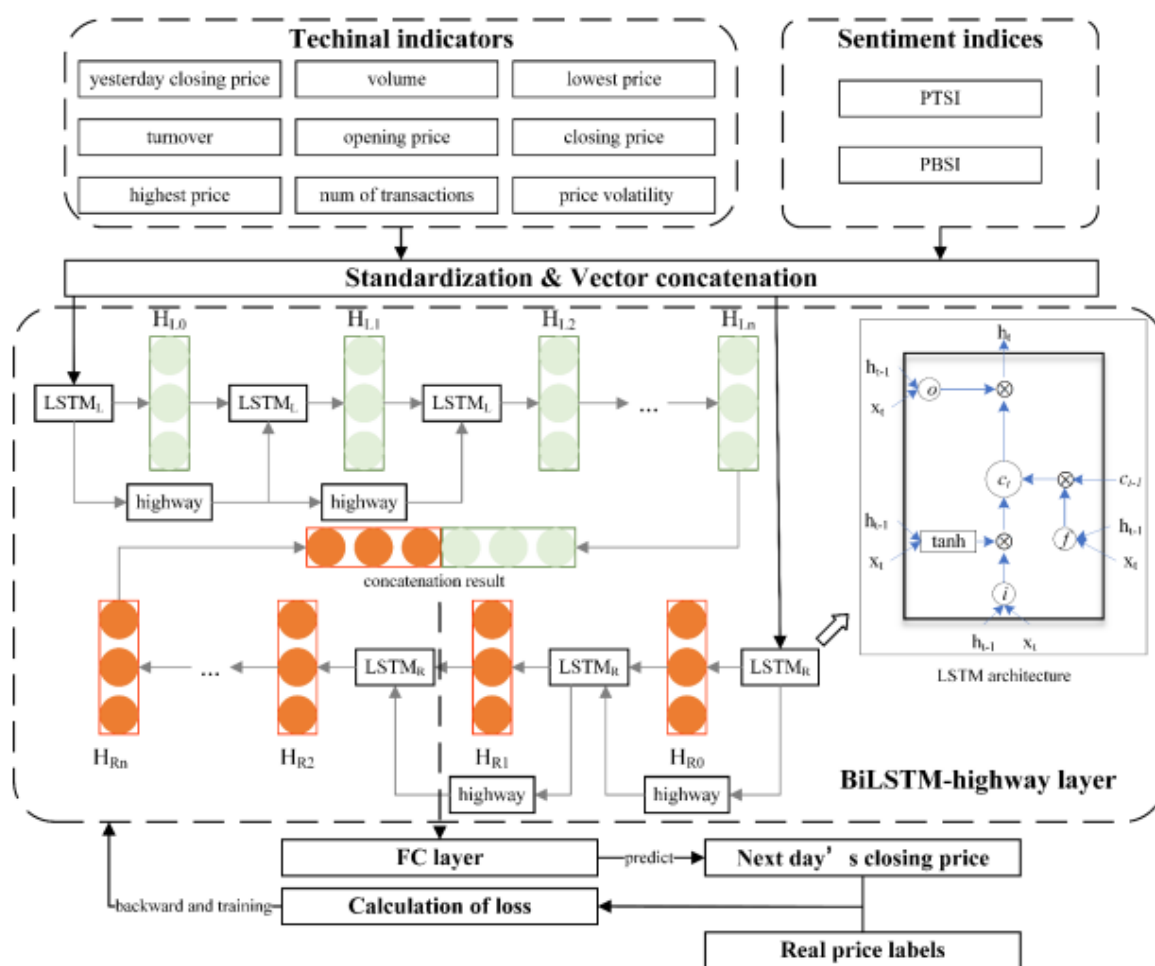


شکل ۸-۰: ساختار مدل CNN با داده‌های ورودی تک متغیره یک هفته گذشته (سن، مهتاب و نا، ۲۰۲۳)



شکل 9-0: ساختار مدل CNN با داده‌های ورودی تک متغیره در دو هفته گذشته (سن، مهتاب و نا، ۲۰۲۳)

در مطالعه (لی و هو^۱، 2024)، یک ساختار یادگیری عمیق ترکیبی برای پیش‌بینی قیمت سهام پیشنهاد می‌شود. این ساختار از مدل XLNET برای تحلیل احساسات منتقل شده در پست‌های کاربران در انجمن‌های آنلاین استفاده و این احساسات را با عامل محبوبیت پست برای محاسبه احساسات روزانه گروه ترکیب می‌کند. سپس این اطلاعات با شاخص‌های فنی سهام در یک مدل بهبود یافته BiLSTM برای پیش‌بینی قیمت سهام ادغام می‌شوند. ارزیابی مدل پیشنهاد شده با استفاده از چهار سهم در بازار سهام چین انجام شده است. شکل 2-10 ساختار کلی مدل پیشنهاد شده برای پیش‌بینی قیمت سهام را نشان می‌دهد.



شکل 0-10: ساختار مدل مبتنی بر XLNET و BiLSTM (لی و هو، ۲۰۲۴)

¹ Li & Hu

در مطالعه (سن^۱ و همکاران، 2023)، رویکردی از مدل سازی ترکیبی برای پیش بینی قیمت سهام با استفاده از روش های یادگیری ماشین مختلف و مدل های مبتنی بر یادگیری عمیق ایجاد شده است. در این آزمایش از مقادیر شاخص NIFTY 50 بورس ملی هند در دوره زمانی 29 دسامبر 2014 تا 31 ژوئیه 2020 استفاده می شود. مدل های یادگیری ماشین استفاده شده، مدل های رگرسیون خطی چند متغیره^۲، نوار رگرسیون تطبیقی چند متغیره^۳ (MARS)، درخت رگرسیون^۴، تجمع بوت استرپ^۵ (Bagging)، تقویت گرادیان شدید^۶ (XGBoost)، جنگل تصادفی، شبکه عصبی مصنوعی و ماشین بردار پشتیبان هستند. طبق نتایج در بین تمام مدل های رگرسیون مبتنی بر یادگیری ماشین و یادگیری عمیق، عملکرد مدل های ترکیبی رگرسیون یادگیری عمیق مبتنی بر LSTM بسیار برتر از مدل های پیش بینی مبتنی بر یادگیری ماشین بود. همچنین این واقعیت را آشکار می کند که تحلیل چند متغیره در رگرسیون مبتنی بر LSTM ایده خوبی نیست، زیرا مدل های تک متغیره در اجرای خود دقیق تر و سریع تر هستند.

مطالعه (چترجی^۷ و همکاران، 2021)، مجموعه ای از سری های زمانی و مدل های مختلف مبتنی بر یادگیری را برای پیش بینی قیمت سهام نشان می دهد. داده های ICICI، Infosys و SUN PHARMA از دوره ژانویه 2004 تا دسامبر 2019 در این مطالعه استفاده شده اند. مدل سری زمانی (هموارسازی نمایی^۸ Holt-Winters)، مدل ARIMA، دو مدل یادگیری ماشین جنگل تصادفی و MARS و دو مدل مبتنی بر یادگیری عمیق یعنی مدل RNN ساده و LSTM در این آزمایش مورد مقایسه قرار گرفته اند. طبق نتایج، مدل MARS بهترین مدل یادگیری ماشین و مدل LSTM بهترین مدل یادگیری عمیق است. اما به طور کلی، برای هر سه مجموعه داده

¹ Sen

² Multivariate linear regression

³ Multivariate adaptive regression spline

⁴ Regression tree

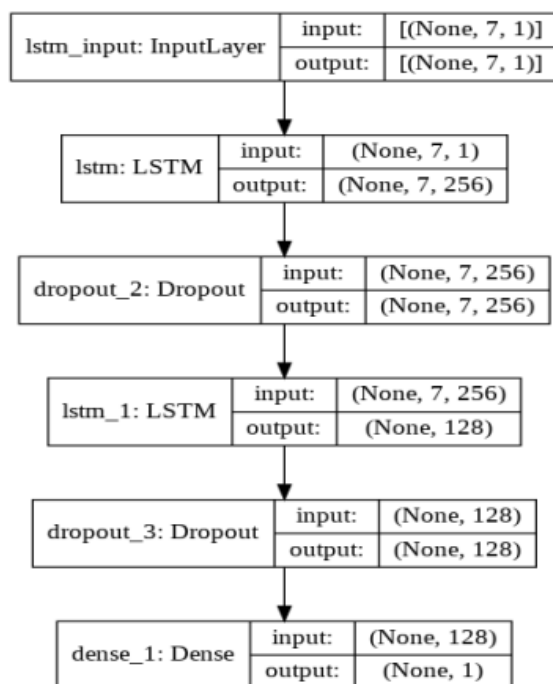
⁵ Bootstrap aggregation

⁶ Extreme gradient boosting

⁷ Chatterjee

⁸ Holt-Winters Exponential Smoothing

مدل MARS بهترین مدل در پیش‌بینی فروش است. شکل 2-11، لایه‌های استفاده شده برای مدل LSTM را نشان می‌دهد.

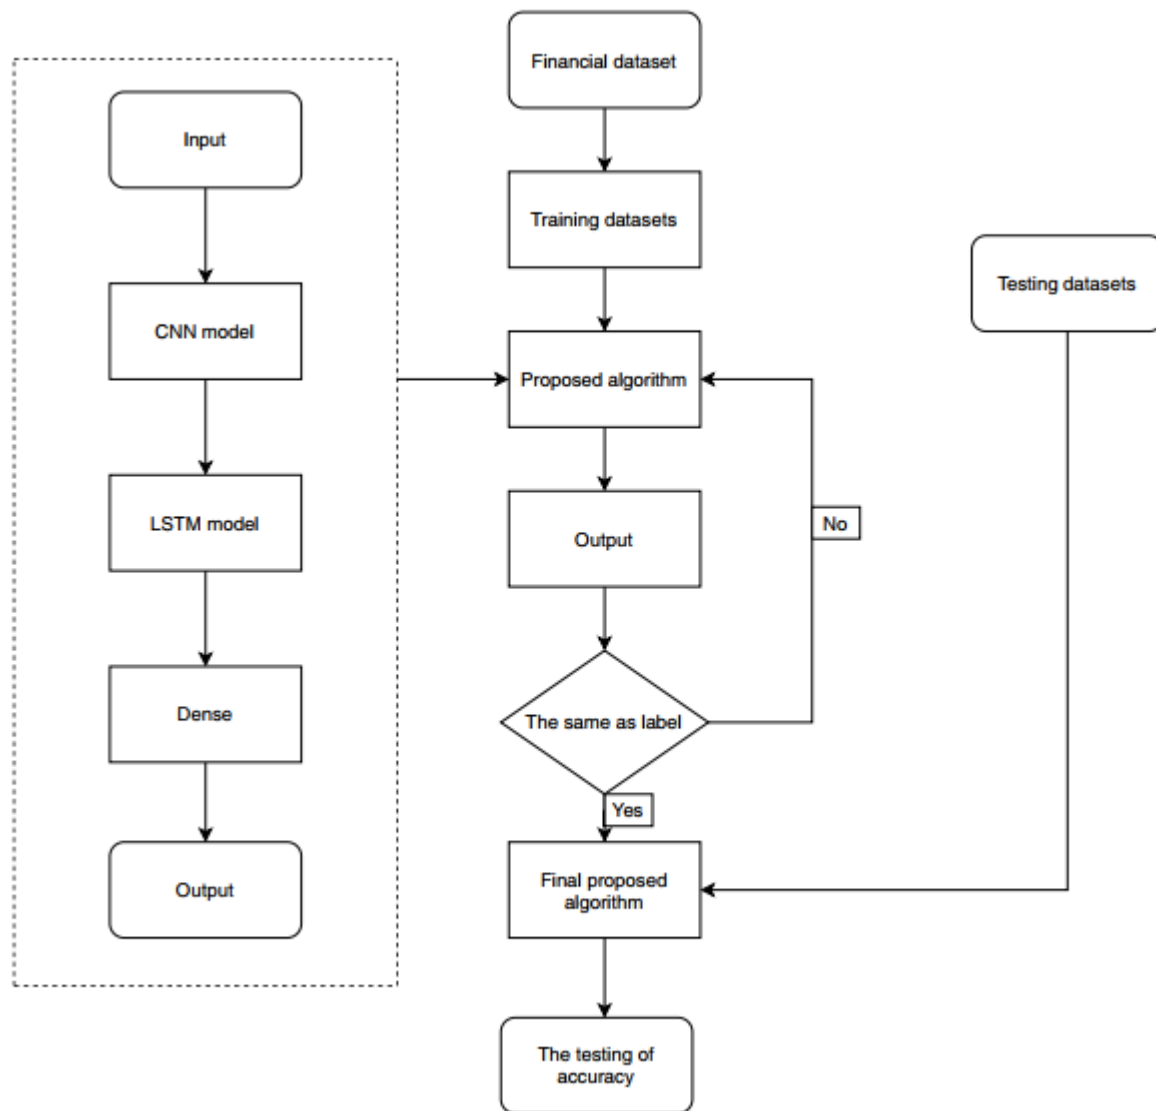


شکل ۱۱-۰: لایه‌های استفاده شده در مدل LSTM (چترجی و همکاران، ۲۰۲۱)

در مطالعه (وو^۱ و همکاران، 2023)، یک ساختار جدید برای دستیابی به پیش‌بینی دقیق‌تر قیمت سهام پیشنهاد شده است که شبکه عصبی پیچشی و LSTM را ترکیب می‌کند و LSTM کانولوشن آرایه دنباله سهام (SACLSTM)^۲ نامیده می‌شود. در این مدل یک آرایه دنباله‌ای از تاریخچه داده‌ها و شاخص‌های اصلی آن ساخته می‌شود و از این آرایه به‌عنوان تصویر ورودی مدل CNN استفاده می‌گردد. سپس مدل CNN بردارهایی را از طریق لایه پیچش و لایه ادغام استخراج می‌کند و این بردارها به‌عنوان ورودی مدل LSTM استفاده می‌شوند. پیش‌بینی در این آزمایش بر روی ده سهام از ایالات متحده و تایوان انجام شده است. شکل 2-12 ساختار مدل SACLSTM را نشان می‌دهد.

^۱ Wu

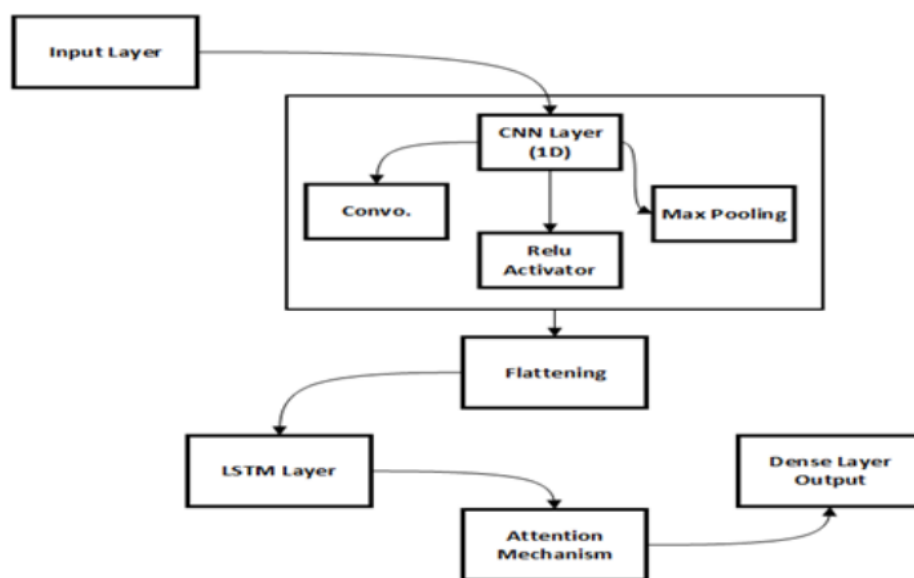
^۲ Sequence array convolutional LSTM



شکل 0-12: ساختار و نحوه اجرای مدل SACLSTM (وو و همکاران، ۲۰۲۳)

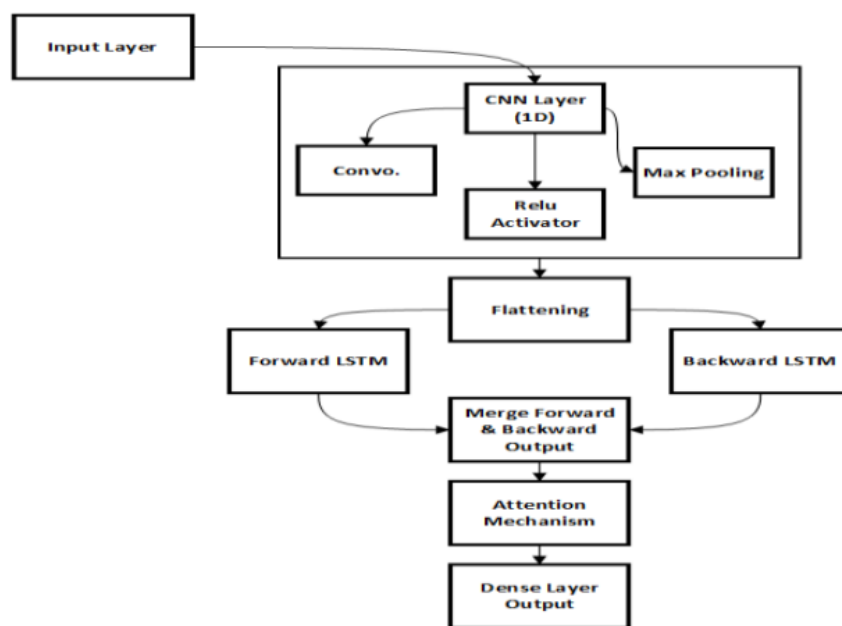
مطالعه (سون و اولاوونمی آساکه، 2024)، از چهار مدل شبکه عصبی CNN، LSTM، CNN-LSTM و CNN- BILSTM برای پیش‌بینی قیمت سهام استفاده می‌کند. مجموعه داده قیمت سهام ایالات متحده از سال 1998-2021 استفاده شده است. طبق نتایج، در حالی که CNN کمترین RMSE و MAE را نشان داد، MAPE بالای آن نشان دهنده قدرت پیش‌بینی محدود است. این نتیجه ممکن است به دلیل تمرکز CNN بر استخراج

ویژگی‌ها به جای وابستگی‌های زمانی باشد که اثربخشی مدل‌های ترکیبی را در گرفتن پویایی‌های پیچیده بازار برجسته می‌کند. مدل CNN-LSTM ترکیبی با مدل مکانیسم توجه^۱، به‌عنوان یک راه‌حل متعادل ظاهر می‌شود و از قدرت استخراج ویژگی‌های CNN و مدیریت متوالی داده‌های LSTM برای دستیابی به RMSE و MAE پایین‌تر و مهم‌تر از همه، کمترین MAPE در بین همه مدل‌ها استفاده می‌کند. همچنین مدل CNN-BiLSTM، با ادغام LSTM‌های دوطرفه، عملکرد متوسطی را نشان می‌دهد. این نتیجه نشان می‌دهد پیچیدگی اضافه شده لزوماً منجر به دقت قابل توجه و بهبود یافته برای این مجموعه داده نمی‌شود. شکل 2-13 ساختار مدل CNN-LSTM و شکل 2-14 ساختار مدل CNN-BiLSTM را نشان می‌دهد.



شکل 0-13: ساختار مدل CNN-LSTM (سون و اولاوونمی آساکه، ۲۰۲۴)

¹ Attention mechanism



شکل 0-14: ساختار مدل CNN-BiLSTM (سون و اولوونمی آساکه، ۲۰۲۴)

5-2 نتیجه گیری

در فصل دوم تحلیلی جامع از چندین رویکرد مورد استفاده در پیش‌بینی قیمت سهام، از جمله مدل‌های آماری، یادگیری ماشین و یادگیری عمیق و رویکردهای ترکیبی معرفی شد. مطالعاتی که از این رویکردها استفاده کرده‌اند، در جدول 1-2 مقایسه شده‌اند. فصل سوم روش پیشنهادی بیان خواهد شد.

جدول 0-۱: مقایسه مطالعات انجام شده در حوزه پیش‌بینی قیمت سهام

دسته‌بندی	منبع	سال	روش	مجموعه داده
سری زمانی	(لاو و ساک، 2023)	2023	ARIMA	ده نماد مختلف سهام شامل صندوق‌های قابل معامله در بورس
	(خندروال و موهانتی، 2021)	2021	ARIMA	داده‌های بورس ملی هند
یادگیرنده ماشین	(لین و	2021	EEMD-MKNN-TSPI	S&P 500, DJI, NAS

Russell 2000 و داده‌های موجودی از 4 منطقه			همکاران، (2021)	
داده‌های بورس اندونزی	جنگل تصادفی	2021	(سیو کور و استیوان، (2021)	
مشخص نشده	KNN	2020	(یانینگ، (2020)	
NSE NYSE	<ul style="list-style-type: none"> MLP RNN LSTM CNN 	2024	(گوش و همکاران، (2024)	یادگیری عمیق
تاریخچه داده‌های قیمت شرکت اپل	BiLSTM	2023	(هان و فو، (2023)	
<ul style="list-style-type: none"> ماشین سازی اراک شرکت پالایش نفت اصفهان گروه سایپا شرکت فولاد مبارکه گروه صنعتی ایران خودرو شرکت ملی صنعت مس ایران شرکت پالایش نفت بندرعباس بانک صادرات ایران 	LSTM	2023	(سالمی متقی و حقیر چهرقانی، (2023)	
بازار سهام چین	<ul style="list-style-type: none"> XLNET BiLSTM 	2024	(لی و هو، (2024)	
مجموعه داده قیمت سهام ایالات متحدہ از سال 1998-2021	<ul style="list-style-type: none"> CNN LSTM CNN-LSTM CNN-BiLSTM 	2024	(سون و اولا وونمی آساکه، (2024)	ترکیبی
شاخص Nifty 50 بورس ملی هند	<ul style="list-style-type: none"> CNN LSTM Encoder-decoder 	2023	(سن، مہتاب و ناث، (2023)	
شاخص Nifty 50 بورس ملی هند	<ul style="list-style-type: none"> رگرسیون خطی چند متغیره MARS 	2023	(سن و	

	<ul style="list-style-type: none"> • درخت رگرسیون • Bagging • XGBoost • RF • ANN • SVM 		همکاران، (2023)	
ده سهام از ایالات متحده و تایوان	مدل ترکیبی SACLSTM مبتنی بر دو مدل CNN و مدل LSTM	2023	(وو و همکاران، (2023)	
Infosys ICICI SUN PHARMA	<ul style="list-style-type: none"> • هموارسازی نمایی Holt-Winters • مدل ARIMA • جنگل تصادفی • RNN • LSTM 	2021	(چترجی و همکاران، (2021)	

فصل سوم

روش‌شناسی تحقیق

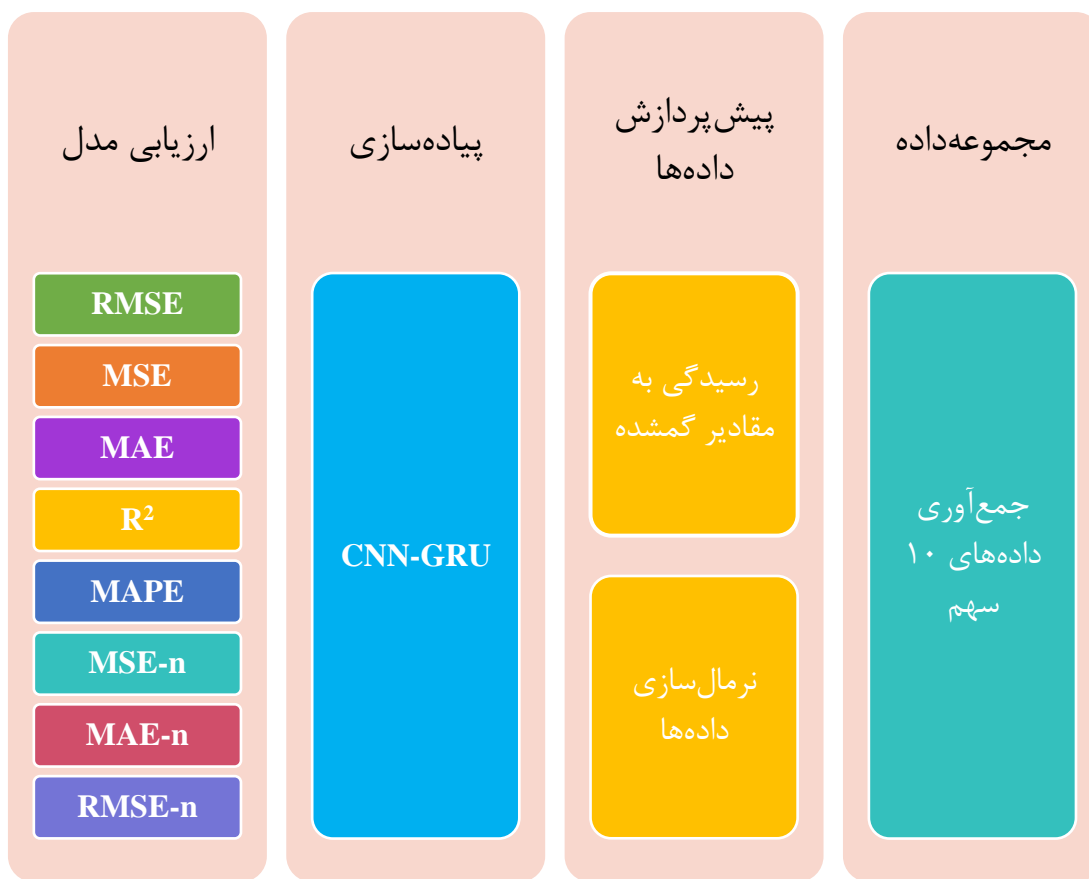
3-1 مقدمه

در فصل دوم مقدمات و مبانی مورد نیاز برای پیش‌بینی قیمت سهام بیان شد. همچنین مطالعاتی که به پیش‌بینی قیمت سهام پرداخته‌اند، مورد بررسی قرار گرفت و مقایسه‌ای بین این مطالعات صورت گرفت. در فصل سوم روش پیشنهادی ارائه می‌شود. مراحل انجام شده در این روش در این فصل شرح داده خواهد شد. همچنین معیارهایی که برای ارزیابی مدل استفاده شده‌اند، نیز در پایان فصل معرفی می‌گردند.

3-2 روش پیشنهادی

شکل 3-1 روش پیشنهادی را نشان می‌دهد. در روش پیشنهاد شده در این پژوهش، ابتدا اطلاعات سهم جمع آوری شد. سپس در مرحله پیش‌پردازش، به داده‌هایی که دارای مقادیر گمشده¹ بودند، رسیدگی شد و تمامی داده‌ها نرمال شدند. سپس این داده‌ها به مدل CNN-GRU پیشنهادی داده شدند. پس از پیاده‌سازی، نتایج با استفاده از معیارهای ارزیابی مورد سنجش قرار گرفت.

¹ Missing values



شکل ۱-۰: روش پیشنهادی

3-3 مجموعه داده

مجموعه داده استفاده شده در این پژوهش شامل اطلاعات نمادهای « همراه، خودرو، شخارکت، شارک، ومعادن، تیپیکو، فارس، خبهمن، کگل، شبهرن» است. این داده‌ها با تهیه مجوز رسمی، از سازمان بورس ایران جمع‌آوری شدند.

ستون‌های مجموعه داده استفاده شده شامل «نام شرکت، نماد، تاریخ، قیمت پایانی، نوسان ریالی (قیمت پایانی)، نوسان درصدی (قیمت پایانی)، آخرین قیمت، نوسان ریالی (آخرین قیمت)، نوسان درصدی (آخرین قیمت)، میانگین قیمت، تعداد خریداران، تعداد دفعات معاملات، حجم، ارزش، ارزش روز، P/E، تعداد سهام کل شرکت» هستند. ویژگی‌های موجود در این مجموعه داده در جدول 3-1 آمده است. هدف پیش‌بینی ویژگی P/E است.

P/E نسبت قیمت سهم به سود هر سهم را محاسبه می‌کند. P/E یک نسبت مهم است که به سرمایه‌گذاران کمک می‌کند تا ارزش سهم یک شرکت را در مقایسه با سود آن ارزیابی کنند. یک P/E پایین‌تر ممکن است نشان‌دهنده قیمت سهم نسبتاً ارزان باشد، در حالی که P/E بالاتر ممکن است نشان‌دهنده قیمت سهم نسبتاً گران باشد. تحلیل P/E به سرمایه‌گذاران کمک می‌کند تا تصمیم بگیرند که آیا سهم یک شرکت ارزش خرید دارد یا خیر.

جدول ۱-۰: ویژگی‌های موجود در مجموعه داده‌ها

نام ویژگی	توضیح
نام شرکت	نام شرکت منتشرکننده سهم.
نماد	کد اختصاری شرکت که در بورس معامله می‌شود.
تاریخ	تاریخ گزارش داده‌ها.
قیمت پایانی	قیمتی که سهم در آخرین معامله روز در بورس خرید و فروش شده است.
نوسان ریالی (قیمت پایانی)	تغییر قیمت ریالی سهم نسبت به قیمت پایانی قبلی.
نوسان درصدی (قیمت پایانی)	درصد تغییر قیمت سهم نسبت به قیمت پایانی قبلی.
آخرین قیمت	آخرین قیمت معامله‌شده سهم در همان روز.
نوسان ریالی (آخرین قیمت)	تغییر قیمت ریالی سهم نسبت به آخرین قیمت قبلی.
نوسان درصدی (آخرین قیمت)	درصد تغییر قیمت سهم نسبت به آخرین قیمت قبلی.
میانگین قیمت	میانگین قیمت معامله‌های انجام‌شده در همان روز.
تعداد خریداران	تعداد سرمایه‌گذارانی که در آن روز سهم را خریداری کرده‌اند.
تعداد دفعات معاملات	تعداد دفعاتی که سهم در آن روز معامله شده است.
حجم	تعداد سهام معامله‌شده در آن روز.
ارزش	ریال ارزش معاملات انجام‌شده در آن روز.

ارزش روز شرکت برحسب آخرین قیمت معامله و تعداد سهام کل شرکت.	ارزش روز
نسبت قیمت به سود هر سهم شرکت.	P/E
تعداد کل سهام منتشر شده شرکت.	تعداد سهام کل شرکت

4-3 پیش پردازش

در مرحله پیش پردازش، رسیدگی به داده‌های گمشده و نرمال سازی داده‌ها انجام شد.

3-4-1 رسیدگی به داده‌های گمشده

داده‌های گمشده به عدم وجود مقادیر یا اطلاعات در فیلدها یا ویژگی‌های خاص در یک مجموعه داده اشاره دارد. به عبارت دیگر، زمانی اتفاق می‌افتد که نقاط داده برای متغیرها یا مشاهدات خاصی در دسترس نباشد یا ثبت نشده باشد. وجود داده‌های گمشده می‌تواند به دلایل مختلفی در حین جمع‌آوری، ذخیره سازی یا پردازش داده‌ها به وجود بیاید (لیتل و روبین^۱، 2019). مدیریت مقادیر گمشده در پیش پردازش داده‌ها برای مدل سازی دقیق بسیار مهم است. روش‌های مختلفی برای رسیدگی به این داده‌ها وجود دارد. جایگذاری^۲ و یا حذف از جمله این روش‌ها هستند. در روش جایگذاری، برای رسیدگی به مقادیر گمشده می‌توان آنها را با میانگین، میانه یا مد پر کرد. این رویکرد ساده است و اغلب زمانی استفاده می‌شود که متغیرها با یکدیگر همبستگی ندارند (لیو^۳ و همکاران، 2014). همچنین حذف سطرها یا ستون‌هایی با مقادیر گمشده روش دیگری برای رسیدگی به این مقادیر است (ژو^۴ و همکاران، 2024). در این پژوهش از روش حذف برای رسیدگی به مقادیر گمشده استفاده شده است.

¹ Little & Rubin

² Imputation

³ Liao

⁴ Zhou

3-4-2 نرمال سازی حداقل - حداکثر

نرمال سازی حداقل - حداکثر، یک روش پیش پردازش در داده‌هاست. هدف این روش تبدیل مقادیر ویژگی به یک محدوده خاص و قابل مقایسه به منظور بهبود عملکرد مدل یادگیری است.

در نرمال سازی حداقل - حداکثر، هر ویژگی به صورت خطی مقیاس بندی می‌شود تا در بازه $[0,1]$ قرار گیرد. نرمال سازی حداقل - حداکثر با استفاده از رابطه 3-1 محاسبه می‌شود.

$$x' = \frac{x - \min(X)}{\max(X) - \min(X)} \quad (1-3)$$

در این رابطه، X مقدار ویژگی اصلی، $\min(X)$ حداقل مقدار ویژگی و $\max(X)$ حداکثر مقدار ویژگی در تمام نقاط داده است (کابلو- سولورزانو¹ و همکاران، 2023).

3-5 مدل پیاده سازی

در پیاده سازی این پژوهش از مدل CNN-GRU استفاده شده است. در این بخش هر قسمت از مدل به همراه لایه‌های پیاده سازی معرفی می‌شوند.

3-5-1 مدل CNN


شبکه عصبی پیچشی² (CNN) نوعی شبکه عصبی یادگیری عمیق است که از ساختار و عملکرد قشر بینایی انسان الهام گرفته شده و برای یادگیری خودکار و سلسله مراتبی ویژگی‌ها از الگوهای سطح پایین تا سطح بالا در داده‌ها طراحی شده است (سیت³ و همکاران، 2020). شکل 3-2 ساختار این مدل را نشان می‌دهد. یک مدل CNN از چند لایه تشکیل می‌شود که در ادامه این لایه‌ها معرفی شده‌اند.

¹ Cabello-Solorzano

² Convolutional neural network

³ Sit

- **لایه‌های پیچش:** این لایه‌ها مجموعه‌ای از فیلترهای قابل یادگیری (هسته‌ها) را اعمال می‌کنند که ویژگی‌ها را از تصویر ورودی استخراج می‌نمایند. هر فیلتر الگوها یا ویژگی‌های خاصی مانند لبه‌ها، شکل‌ها یا بافت‌ها را تشخیص می‌دهد (لکان و همکاران، 1998).
- **لایه‌های ادغام:** این لایه‌ها با اعمال یک عملیات ادغام مانند ادغام حداکثر^۱ یا ادغام میانگین^۲ اطلاعات ویژگی را خلاصه می‌کنند و ابعاد فضایی نقشه‌های ویژگی را کاهش می‌دهند (ژو و چلاپا^۳، 1988).
- **لایه‌های کاملاً متصل:** در پایان معماری CNN، یک یا چند لایه کاملاً متصل وجود دارد که ویژگی‌های سطح بالا را از لایه‌های قبلی گرفته و از آنها برای دسته‌بندی ورودی استفاده می‌کند (لکان و همکاران، 1998).
- **توابع فعال‌سازی:** توابع فعال‌سازی غیرخطی، مانند تابع ReLU (واحد خطی اصلاح‌شده)، پس از لایه‌های پیچش و کاملاً متصل برای بهبود توانایی شبکه در یادگیری الگوهای پیچیده اعمال می‌شوند (سیت و همکاران، 2020).



شکل ۲-۰: ساختار یک مدل CNN (سیت و همکاران، 2020)

¹ Max pooling

² Average pooling

³ Zhou & Chellappa

3-5-2 مدل GRU

مدل GRU نوعی معماری شبکه عصبی بازگشتی^۱ (RNN) است که برای رسیدگی به برخی از چالش‌های پیش روی RNN‌های سنتی، مانند مشکل ناپدید شدن گرادیان^۲ و توانایی یادگیری وابستگی‌های طولانی‌مدت، طراحی شده است (سیت و همکاران، 2020). مدل GRU پیچیدگی را کاهش می‌دهد و در عین حال کارایی را دست‌نخورده نگه می‌دارد. یک نورون GRU تنها یک خروجی را پس از یک سری محاسبات تولید می‌کند و از همان خروجی برای انتقال ویژگی‌های مهم آموخته شده به لایه بعدی و نورون بعدی در همان لایه استفاده می‌نماید (چو^۳ و همکاران، 2014). شبکه عصبی GRU یک ساختار شبکه دایره‌ای است که اطلاعات خروجی جاری را از طریق اطلاعات ورودی در لحظه جاری و اطلاعات خروجی در لحظه قبلی تعیین می‌کند. بنابراین، اطلاعات خروجی در هر لحظه در شبکه عصبی GRU به اطلاعات گذشته بستگی دارد. بنابراین، ویژگی زنجیره‌ای آن ارتباط نزدیکی با مسئله برچسب‌گذاری متوالی دارد. یک شبکه عصبی GRU دارای دو گیت کنترلی یعنی یک گیت تنظیم مجدد^۴ و یک گیت به روز رسانی^۵، مطابق با شکل 3-3 است. گیت تنظیم مجدد تعیین می‌کند که چه مقدار اطلاعات در حالت پنهان لحظه قبل باید فراموش شود. هنگامی که مقدار گیت تنظیم مجدد به 0 نزدیک شود، اطلاعات لحظه قبلی فراموش می‌گردد. وقتی مقدار به 1 نزدیکتر است، اطلاعات پنهان لحظه قبلی در اطلاعات حافظه فعلی حفظ می‌شود. گیت به روز رسانی تعیین می‌کند که چه مقدار اطلاعات در حالت پنهان در لحظه قبل به حالت پنهان فعلی آورده می‌شود. زمانی که مقدار گیت آپدیت به 0 نزدیک شود، اطلاعات در حالت پنهان در لحظه قبل فراموش می‌شود. هنگامی که مقدار به 1 نزدیک شود، اطلاعات در حالت پنهان فعلی حفظ می‌گردد (لی^۶ و همکاران، 2020).

¹ Recurrent neural network


² Vanishing gradient problem

³ Cho

⁴ Reset gate

⁵ Update gate

⁶ Li

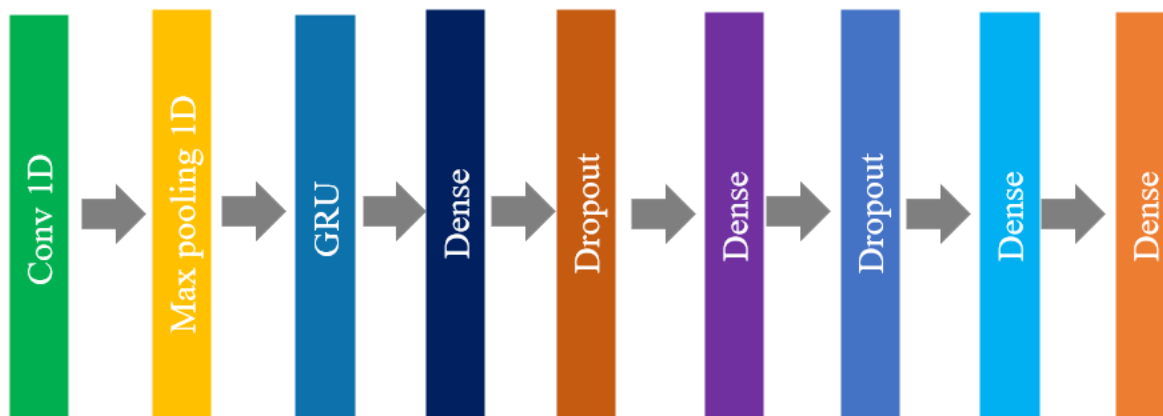


شکل ۳-۰: ساختار مدل GRU (لی و همکاران، ۲۰۲۰)

3-5-3 لایه‌های تشکیل‌دهنده مدل CNN-GRU

لایه‌های مدل CNN-GRU پیشنهادی مطابق با شکل 3-4 است. این لایه‌ها شامل لایه پیچش یک بعدی، Max pooling، GRU، Dense و لایه Dropout هستند. وظیفه لایه پیچش یک بعدی، استخراج ویژگی از داده‌های ورودی یک بعدی است. لایه Max pooling نیز اندازه ورودی را کاهش می‌دهد. پس از این دو لایه، لایه GRU وظیفه پردازش داده‌های متوالی و حفظ اطلاعات مرتبط با آن‌ها را برعهده دارد. همچنین هر نورون در لایه Dense به همه نورون‌های لایه قبلی متصل است. این اتصال باعث می‌شود که هر نورون خروجی، تابعی از همه نورون‌های ورودی باشد. لایه Dropout نیز به طور تصادفی بعضی از نورون‌ها را در طول آموزش، از شبکه خارج می‌کند. این عمل باعث می‌شود که شبکه نتواند بیش از اندازه به داده‌های آموزشی تطبیق یابد. بدین ترتیب از بیش‌برازش^۱ جلوگیری می‌شود و مدل می‌تواند در محیط‌های جدید نیز عملکرد خوبی داشته باشد.

^۱ Overfit



شکل 0-4 : لایه‌های مدل CNN-GRU

3-6 معیارهای ارزیابی

در ارزیابی مدل پیشنهادی از معیارهای میانگین ریشه مربعات خطا¹ (RMSE)، میانگین مربعات خطا² (MSE)، میانگین خطای مطلق³ (MAE)، امتیاز R^2 ⁴، میانگین درصد خطای مطلق⁵ (MAPE) و میانگین درصد خطای مطلق نرمال‌شده⁶ (MAPE-n) استفاده شده است. در این روابط Y_i مقدار واقعی، Y'_i مقدار پیش‌بینی شده است.

3-6-1 میانگین ریشه مربعات خطا

معیار میانگین ریشه مربعات خطا با استفاده از رابطه 3-2 محاسبه می‌شود.

$$RMSE(Y, Y') = \sqrt{MSE(Y, Y')} = \sqrt{\frac{1}{n} \sum_{i=1}^n (Y_i - Y'_i)^2} \quad (2-3)$$

¹ Root Mean Squared Error

² Mean Squared Error

³ Mean Absolute Error

⁴ Root Mean Squared Error

⁵ Mean absolute percentage error

⁶ Normalized mean absolute percentage error

3-6-2 میانگین مربعات خطا

معیار میانگین مربعات خطا با استفاده از رابطه 3-3 قابل محاسبه است.

$$MSE(Y, Y') = \frac{1}{n} \sum_{i=1}^n (Y_i - Y'_i)^2 = \frac{1}{n} \sum_{i=1}^n e_i^2 \quad (3-3)$$

3-6-3 میانگین خطای مطلق

با استفاده از رابطه 4-3 معیار میانگین خطای مطلق محاسبه می‌شود.

$$MAE(Y, Y') = \frac{1}{n} \sum_{i=1}^n |Y_i - Y'_i| = \frac{1}{n} \sum_{i=1}^n |e_i| \quad (4-3)$$

3-6-4 معیار امتیاز R^2

معیار R^2 نشان‌دهنده نسبت واریانس برای متغیر وابسته است که توسط متغیرهای مستقل در مدل توضیح داده شده است. مقادیر R^2 از 0 تا 1 متغیر است و مقادیر بالاتر تناسب بهتر مدل با داده‌ها را نشان می‌دهد. این معیار با استفاده از رابطه 5-3 قابل محاسبه است.

$$R^2(Y, Y') = 1 - \frac{\sum_{i=1}^n (Y_i - Y'_i)^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2} \quad (5-3)$$

3-6-5 معیار میانگین درصد خطای مطلق

میانگین درصد خطای مطلق، دقت را به صورت درصد بیان می‌کند و تفسیر مدل را آسان می‌نماید. با استفاده از رابطه 6-3 این معیار محاسبه می‌شود. مقدار MAPE کمتر نشان‌دهنده دقت پیش‌بینی بهتر است.

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{Y_i - Y'_i}{Y_i} \right| \quad (6-3)$$

3-6-6 معیار میانگین درصد خطای مطلق نرمال شده

برای محاسبه این معیار از رابطه 3-7 استفاده می‌شود.

$$NMAPE = \frac{\frac{1}{n} \sum_{i=1}^n \left| \frac{Y_i - Y'_i}{Y_i} \right|}{var(Y)} \quad (3-7)$$

که $var(Y)$ برابر با مقدار واریانس Y است.

3-7 نتیجه‌گیری

در فصل سوم روش پیشنهادی معرفی شد. در این روش، پس از استخراج و پیش‌پردازش داده‌ها از مدل CNN-GRU استفاده می‌شود. همچنین معیارهای ارزیابی که برای سنجش مدل استفاده شده‌اند، در این فصل مورد بررسی قرار گرفت و نحوه محاسبه هریک از این معیارها بیان شد. در فصل چهارم جزئیات پیاده‌سازی روش پیشنهادی و همچنین نتایج ارزیابی مدل بیان خواهد شد.

فصل چهارم

پیاده‌سازی و نتایج پژوهش

4-1 مقدمه

در فصل سوم، روش پیشنهادی مورد بررسی قرار گرفت و مراحل اجرای این روش بیان گردید. در فصل چهارم به جزئیات پیاده‌سازی روش پیشنهادی پرداخته شده است. همچنین نتایج ارزیابی مدل پس از اجرا در ادامه آورده خواهد شد.

4-2 مجموعه داده و پیش پردازش داده‌ها

داده‌های استفاده شده در این پژوهش مستقیماً از سازمان بورس و اوراق بهادار تهران جمع‌آوری گردید.

شکل 4-1 نمایی از این داده‌ها را نشان می‌دهد. این مجموعه داده از ۱۷ ستون و ۲۰۹۲۴۷ داده تشکیل شده

است که این داده‌ها حاوی اطلاعات سهام ۱۰ شرکت است. هدف این پژوهش پیش‌بینی مقادیر ستون P/E است.

تعداد دفعات تعداد خریدار(میانگین قیمت) %	نوسان ریالی	آخرین قیمت(تعداد پایانی) %	نوسان ریالی	قیمت پایانی	تاریخ	نماد	شرکت							
ارزش	حجم													
P/E ارزش روز	331,797,000,000	2,898,833,300	500,000	138	51	5,798	11.39	5821	595	11.39	5,821	1381/01/C	فاندر	آذرب
5.64	57,000,000	332,880,000,000	3,008,779,640	105	32	5,848	0.33	5840	19	0.33	5,840	1381/01/1	فاندر	آذرب
5.65	57,000,000	341,202,000,000	1,498,158,000	71	28	5,922	2.5	5986	146	2.5	5,986	1381/01/1	فاندر	آذرب
5.79	57,000,000	349,695,000,000	3,288,360,000	129	22	6,135	2.49	6135	149	2.49	6,135	1381/01/1	فاندر	آذرب
5.94	57,000,000	349,695,000,000	1,432,150	48	18	6,141	0	6135	0	0	6,135	1381/01/1	فاندر	آذرب
5.94	57,000,000	349,923,000,000	689,356,448	34	7	6,136	0.07	6139	4	0.07	6,139	1381/01/1	فاندر	آذرب
5.94	57,000,000	349,980,000,000	846,680,269	14	45	6,141	0.02	6140	1	0.02	6,140	1381/01/1	فاندر	آذرب
5.94	57,000,000	350,037,000,000	1,005,494,715	20	51	6,141	0.02	6141	1	0.02	6,141	1381/01/2	فاندر	آذرب
5.94	57,000,000	350,037,000,000	635,289,040	12	18	6,142	0	6141	0	0	6,141	1381/01/2	فاندر	آذرب
5.95	57,000,000	350,094,000,000	733,320,972	31	12	6,142	0.02	6142	1	0.02	6,142	1381/01/2	فاندر	آذرب
5.96	57,000,000	350,892,000,000	394,700,745	17	10	6,149	0.23	6156	14	0.23	6,156	1381/01/2	فاندر	آذرب
6.11	57,000,000	359,613,000,000	85,395,360	13	8	6,265	2.49	6309	153	2.49	6,309	1381/01/2	فاندر	آذرب
6.26	57,000,000	368,505,000,000	73,307,750	13	6	6,463	2.47	6465	156	2.47	6,465	1381/01/2	فاندر	آذرب
6.28	57,000,000	369,702,000,000	578,306,359	34	15	6,476	0.32	6486	21	0.32	6,486	1381/01/2	فاندر	آذرب
6.44	57,000,000	378,936,000,000	63,089,520	10	1	6,648	2.5	6648	162	2.5	6,648	1381/01/3	فاندر	آذرب
6.6	57,000,000	388,398,000,000	34,070,000	2	5	6,814	2.5	6814	166	2.5	6,814	1381/02/C	فاندر	آذرب
6.76	57,000,000	398,088,000,000	1,088,592,080	43	16	6,984	2.49	6984	170	2.49	6,984	1381/02/C	فاندر	آذرب
6.83	57,000,000	402,021,000,000	705,300,000	26	9	7,053	0.99	7053	69	0.99	7,053	1381/02/C	فاندر	آذرب
6.9	57,000,000	406,011,000,000	82,790,629	5	1	7,123	0.99	7123	70	0.99	7,123	1381/02/C	فاندر	آذرب

شکل ۱-۰: بخشی از مجموعه داده

پس از استخراج مجموعه داده، داده‌هایی که دارای مقادیر گم‌شده بودند، از مجموعه داده حذف شدند. سپس روش نرمال‌سازی حداقل-حداکثر بر روی داده‌ها اعمال گردید. سپس 90 درصد از داده‌ها برای آموزش مدل، 5 درصد برای اعتبارسنجی و 5 درصد نیز برای آزمایش مدل تقسیم شدند.

3-4 پیاده‌سازی مدل

در پیاده‌سازی مدل ابتدا هایپرپارامترهای ضروری تنظیم شدند. انتخاب دقیق این هایپرپارامترها به اجرا و تعمیم‌پذیری بهتر مدل کمک می‌کند. هایپرپارامترها مطابق با جدول 4-1 تنظیم شدند. مطابق با این جدول، تابع ضرر^۱، تابع فعال‌ساز^۲ و تابع بهینه‌ساز^۳ به ترتیب Mean squared error، Relu و Adam انتخاب شدند. همچنین پیاده‌سازی در 200 اپوک^۴ و با اندازه دسته^۵ 64 انجام شد.

جدول ۱-۰: هایپرپارامترهای انتخاب شده در پیاده‌سازی مدل

هایپرپارامتر	مقدار تنظیم شده
تابع ضرر	Mean squared error
تابع فعال‌ساز	Relu
تعداد اپوک	200
اندازه دسته	64
تابع بهینه‌ساز	Adam

¹ Loss

² Activation

³ Optimizer

⁴ Epoch

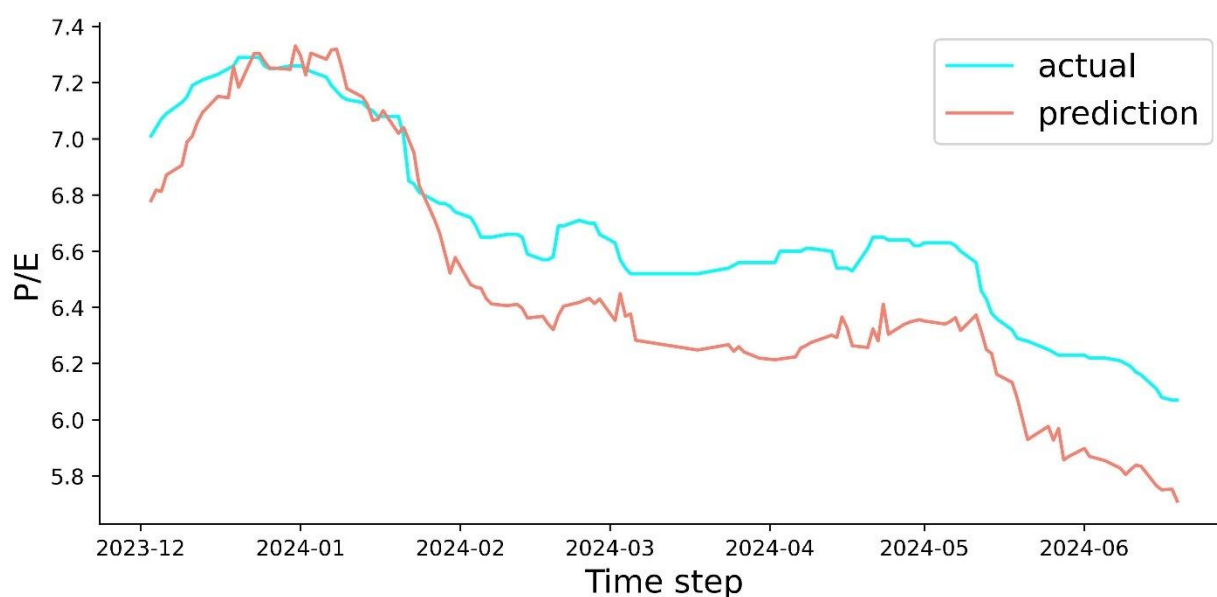
⁵ Batch size

4-4 ارزیابی نتایج

در این بخش نتایج به دست آمده، پس از ارزیابی مدل CNN-GRU پیشنهادی ارائه شده است.

4-4-1 سهام تیپیکو

شکل 4-2 نمودار ارزش سهام تیپیکو را نشان می‌دهد. طبق این شکل، نمودار پیش‌بینی ارزش سهام تیپیکو تا تاریخ 2024-2 روندی مشابه با نمودار ارزش واقعی این سهام دارد. بعد از این تاریخ، مقدار پیش‌بینی شده برای ارزش این سهام در مقایسه با مقدار واقعی، کمتر است.



شکل ۲-۰ : نمودار پیش‌بینی ارزش سهام تیپیکو


نتایج ارزیابی مدل CNN-GRU با استفاده از معیارهای ارزیابی برای سهام تیپیکو در جدول 4-2 آمده است. با توجه به این جدول مقدار خطای MAPE، RMSE، MSE و MAE به ترتیب برابر با 0.033، 0.242، 0.058 و 0.214 است. همچنین معیار R^2 برابر با 0.502 است.

جدول ۲-۰: نتایج ارزیابی مدل برای سهام تیپیکو

نام سهام	MAE	MSE	RMSE	R^2	MAPE-n	MAPE
تیپیکو	0.214	0.058	0.242	0.502	0.064	0.033

4-2-4 خبهمن

شکل 3-4 نمودار پیش‌بینی ارزش سهام خبهمن را درمقابل نمودار ارزش واقعی این سهم نشان می‌دهد. طبق این شکل، روند صعود و نزول هر دو نمودار ارزش واقعی و ارزش پیش‌بینی شده توسط مدل CNN-GRU مشابه یکدیگر است. البته دو نمودار اختلافاتی دارند و نمودار پیش‌بینی ارزش همواره مقداری کمتر از ارزش واقعی سهام را پیش‌بینی کرده است.



شکل ۳-۰: نمودار پیش‌بینی ارزش سهام خبهمن

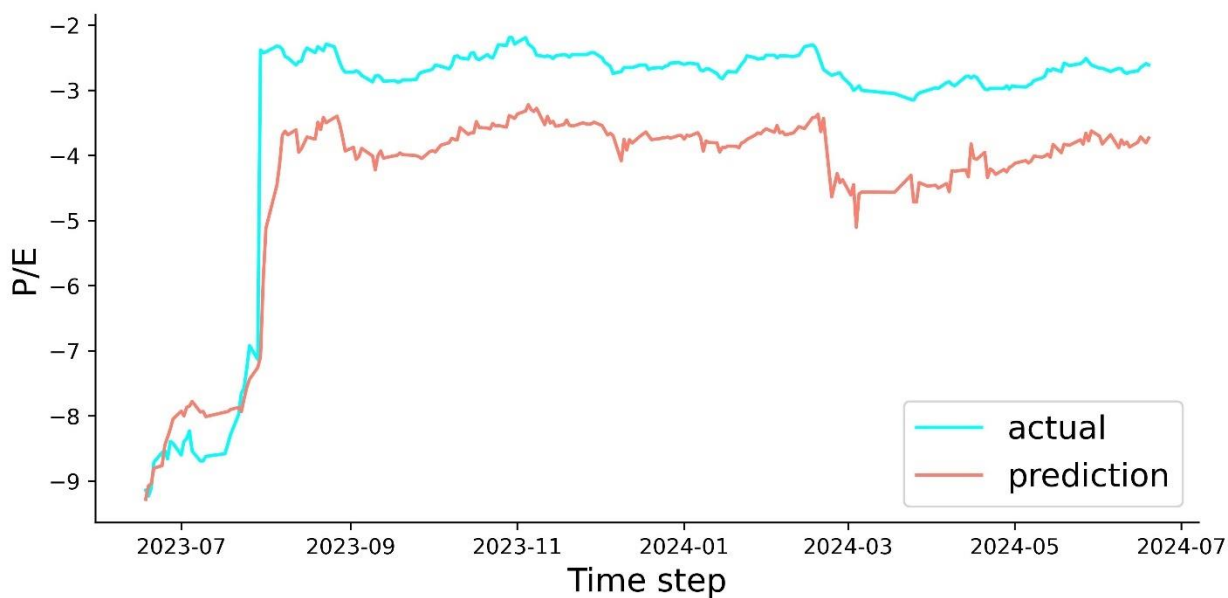
نتایج ارزیابی مدل CNN-GRU با استفاده از معیارهای ارزیابی برای سهام خبهمن در جدول 3-4 آمده است. با توجه به این جدول مقدار خطای MAPE، RMSE، MSE و MAE به ترتیب برابر با 0.26، 5.716، 32.677 و 4.505 است. همچنین معیار R^2 برابر با 0.542 و مقدار MAPE-n برابر با 0.292 است.

جدول ۳-۰: نتایج ارزیابی مدل برای سهام خبهمن

نام سهام	MAE	MSE	RMSE	R^2	MAPE-n	MAPE
خبهمن	4.505	32.677	5.716	0.542	0.292	0.26

3-4-4 خودرو

شکل 4-4 نمودار پیش‌بینی ارزش سهام خودرو را در مقابل نمودار ارزش واقعی این سهم نشان می‌دهد. مطابق با این شکل، نمودار پیش‌بینی همواره مقداری کمتر از مقدار واقعی ارزش سهام خودرو را تخمین زده است.



شکل ۴-۰: نمودار پیش‌بینی ارزش سهام خودرو

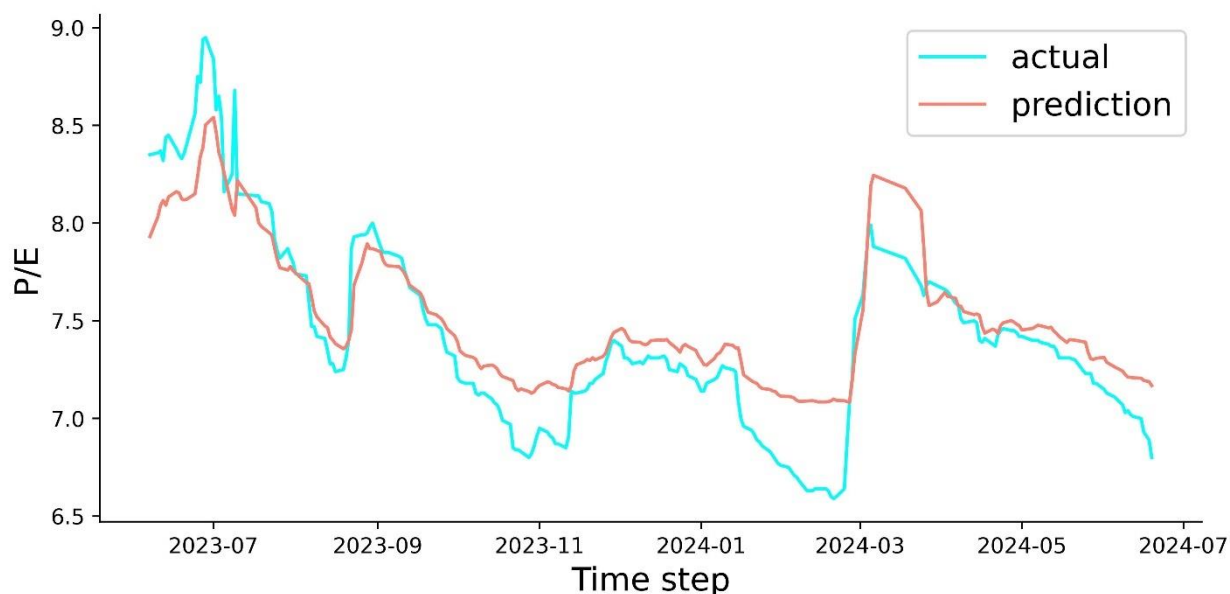
نتایج ارزیابی مدل CNN-GRU با استفاده از معیارهای ارزیابی برای سهام خودرو در جدول 4-4 آمده است. با توجه به این جدول مقدار خطای MAPE، RMSE، MSE و MAE به ترتیب برابر با 0.423، 1.221، 1.49 و 1.137 است. همچنین معیار R^2 برابر با 0.548 و مقدار MAPE-n برابر با 0.028 است.

جدول ۴-۰: نتایج ارزیابی مدل برای سهام خودرو

نام سهام	MAE	MSE	RMSE	R^2	MAPE-n	MAPE
خودرو	1.137	1.49	1.221	0.548	0.028	0.423

4-4-4 شاراکی

شکل 4-5 نمودار پیش‌بینی ارزش سهام شاراک را در مقابل نمودار ارزش واقعی این سهم نشان می‌دهد. مطابق با این شکل هر دو نمودار پیش‌بینی و ارزش سهام شاراک روندی مشابه یکدیگر دارند. با این حال مقدار ارزش پیش‌بینی شده برای سهام شاراک در برخی نقاط از مقدار واقعی ارزش این سهام بیشتر تخمین زده شده است.



شکل ۵-۰: نمودار پیش‌بینی ارزش سهام شاراک


نتایج ارزیابی مدل CNN-GRU با استفاده از معیارهای ارزیابی برای سهام شراک در جدول 4-5 آمده است. با توجه به این جدول مقدار خطای MAPE، RMSE، MSE و MAE به ترتیب برابر با 0.023، 0.215، 0.46 و 0.17 است. همچنین معیار R2 برابر با 0.818 و مقدار MAPE-n برابر با 0.027 است.

جدول ۵-۰: نتایج ارزیابی مدل برای سهام شراک

MAPE	MAPE-n	R ²	RMSE	MSE	MAE	نام سهام
0.023	0.027	0.818	0.215	0.046	0.17	شاراک

4-5-4 شپهرن

شکل 4-6 نمودار پیش‌بینی ارزش سهام شپهرن را در مقابل نمودار ارزش واقعی این سهم نشان می‌دهد. با توجه به نمودار پیش‌بینی شده توسط مدل و مقایسه آن با نمودار ارزش واقعی سهام، از ابتدا این دو نمودار روندی مشابه یکدیگر دارند. با وجود اینکه در طول اجرا دو نمودار مقدار واقعی و مقدار پیش‌بینی شده سهام شپهرن اختلافاتی با یکدیگر دارند، اما در انتها این دو نمودار منطبق بر یکدیگر هستند.



شکل ۶-۰: پیش‌بینی ارزش سهام شپهرن

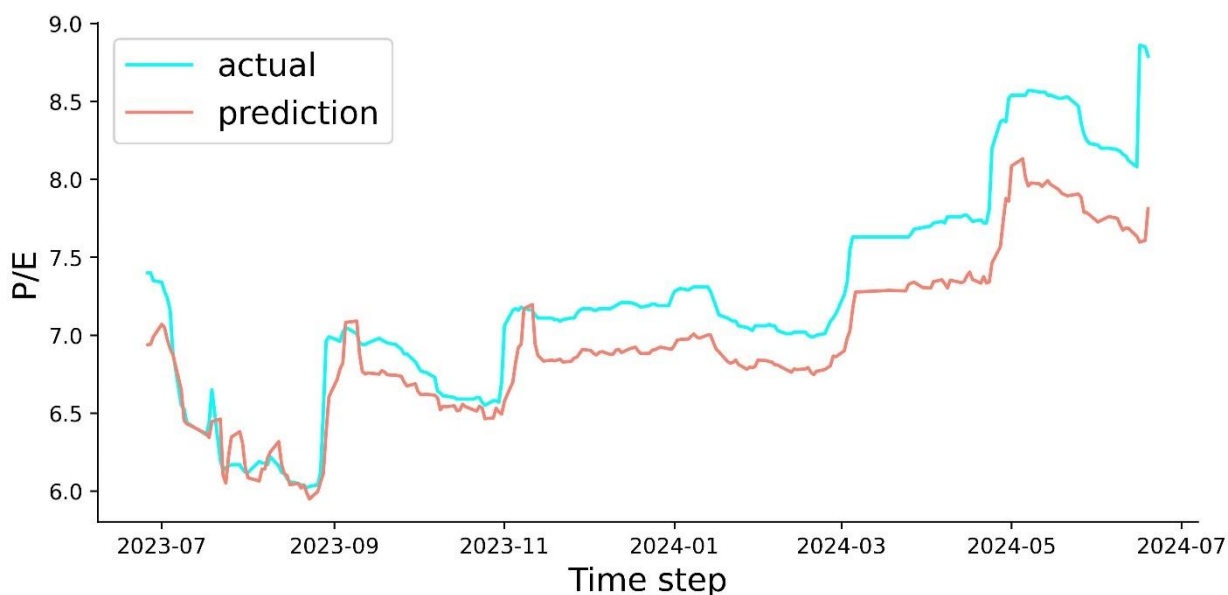
نتایج ارزیابی مدل CNN-GRU با استفاده از معیارهای ارزیابی برای سهام شپهرن در جدول 4-6 آمده است. با توجه به این جدول مقدار خطای MAPE، RMSE، MSE و MAE به ترتیب برابر با 0.08، 1.046، 1.095 و 0.651 است. همچنین معیار R^2 برابر با 0.776 و مقدار MAPE-n برابر با 0.116 است.

جدول ۶-۰: نتایج ارزیابی مدل برای سهام شبهرن

نام سهام	MAE	MSE	RMSE	R^2	MAPE-n	MAPE
شبهرن	0.651	1.095	1.046	0.776	0.116	0.08

4-4-6 شخارک

شکل 4-7 نمودار پیش‌بینی ارزش سهام شخارک را درمقابل نمودار ارزش واقعی این سهم نشان می‌دهد. طبق نمودار پیش‌بینی و ارزش واقعی، هر دو نمودار حرکات مشابهی دارند. نمودار پیش‌بینی ارزش سهام بعد از اجرای ابتدایی اگرچه با نمودار واقعی انطباق کمی دارد، اما در ادامه اجرا مقدار پیش‌بینی شده برای ارزش سهام شخارک کمتر از مقدار ارزش واقعی این سهم است.



شکل ۷-۰: نمودار پیش‌بینی ارزش سهام شخارک


نتایج ارزیابی مدل CNN-GRU با استفاده از معیارهای ارزیابی برای سهام شخارک در جدول 4-7 آمده است. باتوجه به این جدول مقدار خطای MAPE، RMSE، MSE و MAE به ترتیب برابر با 0.037، 0.342، 0.117 و 0.282 است. همچنین معیار R^2 برابر با 0.743 و مقدار MAPE-n برابر با 0.047 است.

جدول ۷-۰: نتایج ارزیابی مدل برای سهام شخارک

نام سهام	MAE	MSE	RMSE	R^2	MAPE-n	MAPE
شخارک	0.282	0.117	0.342	0.743	0.047	0.037

4-4-7 فارس

شکل 4-8 نمودار پیش بینی ارزش سهام فارس را درمقابل نمودار ارزش واقعی این سهم نشان می دهد. طبق این دو نمودار، حرکات مشابه یکدیگر است. با این حال نمودار پیش بینی تخمینی بالاتر از مقدار ارزش واقعی سهام فارس داشته است.



شکل ۸-۰: نمودار پیش‌بینی ارزش سهام فارس


نتایج ارزیابی مدل CNN-GRU با استفاده از معیارهای ارزیابی برای سهام فارس در جدول ۴-۸ آمده است. باتوجه به این جدول مقدار خطای MAPE، RMSE، MSE و MAE به ترتیب برابر با 0.124، 0.852، 0.726 و 0.805 است. همچنین معیار R^2 برابر با 0.585 و مقدار MAPE-n برابر با 0.124 است.

جدول ۸-۰: نتایج ارزیابی مدل برای سهام فارس

نام سهام	MAE	MSE	RMSE	R^2	MAPE-n	MAPE
فارس	0.805	0.726	0.852	0.585	0.124	0.124

4-8-4 کگل

شکل 4-9 نمودار پیش‌بینی ارزش سهام کگل را در مقابل نمودار ارزش واقعی این سهم نشان می‌دهد. طبق این شکل، نمودار پیش‌بینی ارزش سهام در ابتدای اجرا مقداری کمتر از مقدار واقعی را تخمین می‌زند. اما با ادامه اجرا، نمودار مقدار واقعی و پیش‌بینی به یکدیگر نزدیک شده و منطبق می‌شوند.



شکل ۹-۰: نمودار پیش‌بینی ارزش سهام کگل

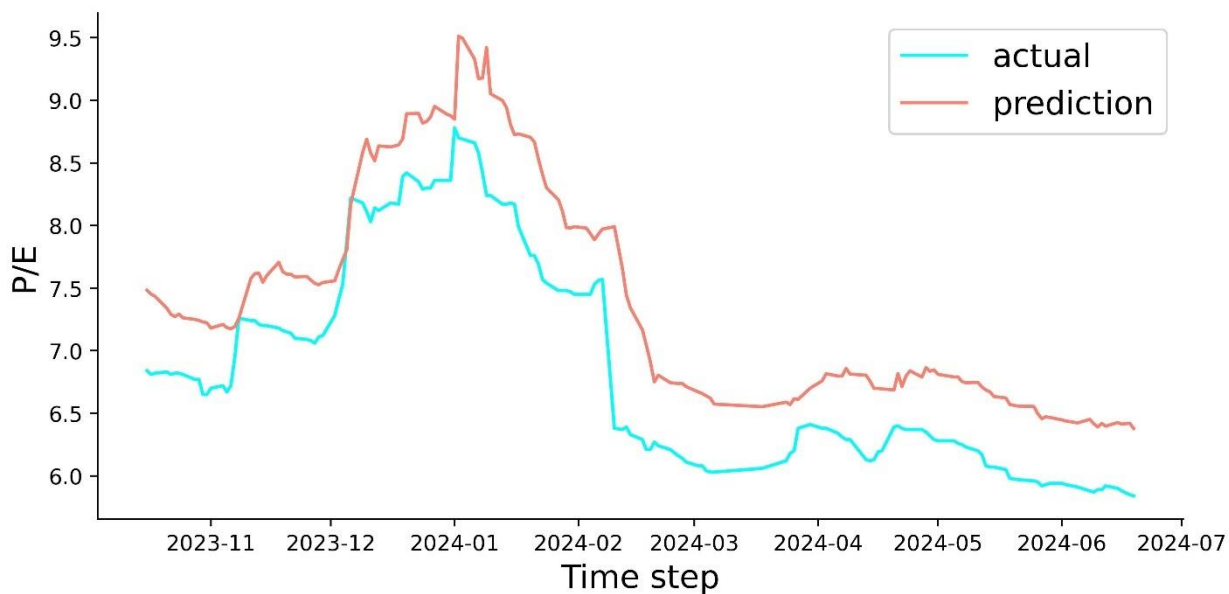
نتایج ارزیابی مدل CNN-GRU با استفاده از معیارهای ارزیابی برای سهام کگل در جدول 4-9 آمده است. باتوجه به این جدول مقدار خطای MAPE، RMSE، MSE و MAE به ترتیب برابر با 0.066، 0.77، 0.593 و 0.631 است. همچنین معیار R^2 برابر با 0.555 و مقدار MAPE-n برابر با 0.086 است.

جدول ۹-۰: نتایج ارزیابی مدل برای سهام کگل

نام سهام	MAE	MSE	RMSE	R^2	MAPE-n	MAPE
کگل	0.631	0.593	0.77	0.555	0.086	0.066

4-4-9 همراه

شکل 4-10 نمودار پیش‌بینی ارزش سهام همراه را در مقابل نمودار ارزش واقعی این سهم نشان می‌دهد. طبق این دو نمودار، حرکات مشابه یکدیگر است، با این حال نمودار پیش‌بینی تخمینی بالاتر از مقدار واقعی دارد.



شکل 4-10: نمودار پیش‌بینی ارزش سهام همراه

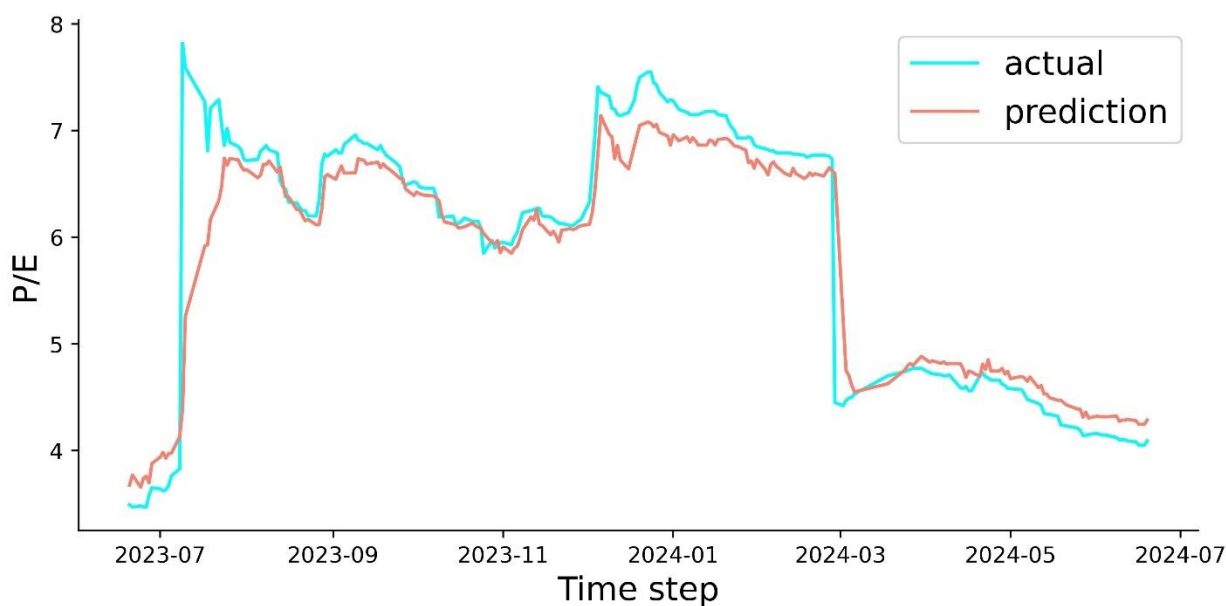
نتایج ارزیابی مدل CNN-GRU با استفاده از معیارهای ارزیابی برای سهام همراه در جدول 4-10 آمده است. باتوجه به این جدول مقدار خطای MAPE، RMSE، MSE و MAE به ترتیب برابر با 0.08، 0.576، 0.332 و 0.541 است. همچنین معیار R^2 برابر با 0.546 و مقدار MAPE-n برابر با 0.08 است.

جدول ۱۰-۰: نتایج ارزیابی مدل برای سهام همراه

نام سهام	MAE	MSE	RMSE	R^2	MAPE-n	MAPE
همراه	0.541	0.332	0.576	0.546	0.08	0.08

4-4-10 معادن

شکل 4-11 نمودار پیش‌بینی ارزش سهام و معادن را در مقابل نمودار ارزش واقعی این سهم نشان می‌دهد. طبق شکل، این دو نمودار حرکتی مشابه با یکدیگر دارند و صعود و نزول آنها کاملاً مطابق با یکدیگر است. اختلافات پیش‌بینی بین مقدار واقعی ارزش سهام با مقدار تخمین زده شده نیز بسیار اندک است، به نحوی که دو نمودار تقریباً منطبق بر یکدیگر هستند.



شکل ۱۱-۰: نمودار پیش‌بینی ارزش سهام و معادن

نتایج ارزیابی مدل CNN-GRU با استفاده از معیارهای ارزیابی برای سهام ومعادن در جدول 4-11 آمده است. باتوجه به این جدول مقدار خطای MAPE، RMSE، MSE و MAE به ترتیب برابر با 0.038، 0.4، 0.16 و 0.225 است. همچنین معیار R^2 برابر با 0.89 و مقدار MAPE-n برابر با 0.061 است.

جدول ۱۰-۱: نتایج ارزیابی مدل برای سهام ومعادن

نام سهام	MAE	MSE	RMSE	R^2	MAPE-n	MAPE
ومعادن	0.225	0.16	0.4	0.89	0.061	0.038

4-5 مقایسه نتایج

به منظور مقایسه بهتر نتایج پیش بینی شده برای ارزش هر سهام، نتایج ارزیابی هر سهم مطابق با جدول 4-12 به دست آمد. مطابق با این جدول مقدار معیار R^2 برای سهام شخارک، شارک، ومعادن و شبهرن به ترتیب برابر با 0.743، 0.818، 0.89 و 0.776 شده که در مقایسه با سایر سهام بالاترین مقدار R^2 به دست آمده است. بنابراین مدل CNN-GRU پیشنهادی برای این سهام بهتر از سایرین عمل کرده است. با این حال برای سایر سهام نیز این مدل عملکرد خوبی داشته است. این موضوع با در نظر گرفتن مقادیر و معیارهای متعدد خطای محاسبه شده استنباط می گردد. در این جدول، سهام شاراک با مقدار MAE برابر با 0.17 دارای کمترین خطای مطلق است و سهام خبهمن با MAE برابر با 4.505 بیشترین خطا را دارد. همچنین سهام شاراک با مقدار RMSE برابر با 0.215 دارای کمترین خطای ریشه میانگین مربعات است و سهام خبهمن با مقدار RMSE برابر با 5.716 بیشترین خطا را دارد. در این جدول، سهام ومعادن با مقدار R^2 برابر با 0.89 دارای بالاترین R^2 شده است و سهام تیپیکو با مقدار R^2 برابر با 0.502 کمترین R^2 را دارد. سهام شاراک با مقدار MAPE-n برابر با 0.027 دارای کمترین خطای درصدی نرمال شده است و سهام خبهمن با مقدار MAPE-n برابر با 0.292

بیشترین خطا را دارد. علاوه بر این، سهام شاراک با مقدار MAPE برابر با 0.023 دارای کمترین خطای MAPE است و سهام فارس با مقدار MAPE برابر با 0.124 بیشترین خطای MAPE را دارد. در مجموع، سهام شاراک دارای بهترین عملکرد پیش‌بینی است، زیرا در اکثر معیارها نتایج بهتری دارد. در مقابل، سهام خبهمن ضعیف‌ترین عملکرد را نشان می‌دهد.

جدول ۰-۱۲: نتایج ارزیابی مدل CNN-GRU برای همه سهام بررسی شده

نام سهام	MAE	MSE	RMSE	R ²	MAPE-n	MAPE
همراه	0.541	0.332	0.576	0.546	0.08	0.08
خودرو	1.137	1.49	1.221	0.548	0.028	0.423
شخارک	0.282	0.117	0.342	0.743	0.047	0.037
شاراک	0.17	0.046	0.215	0.818	0.027	0.023
ومعادن	0.225	0.16	0.4	0.89	0.061	0.038
تیپیکو	0.214	0.058	0.242	0.502	0.064	0.033
فارس	0.805	0.726	0.852	0.585	0.124	0.124
خبهمن	4.505	32.677	5.716	0.542	0.292	0.26
کگل	0.631	0.593	0.77	0.555	0.086	0.066
شبهرن	0.651	1.095	1.046	0.776	0.116	0.08

4-6 نتیجه‌گیری

در فصل چهارم جزئیات پیاده‌سازی مدل پیشنهادی بیان شد. همچنین نتایج ارزیابی مدل CNN-GRU که پس از پیاده‌سازی این مدل به دست آمده است، مورد بررسی قرار گرفت. طبق نتایج ارزیابی، مدل CNN-GRU می‌تواند مقادیر ارزش یک سهم را پیش‌بینی نماید و مقادیر پیش‌بینی شده به مقدار ارزش واقعی سهام نزدیک هستند. معیارهایی مانند R^2 و معیارهای سنجش خطا این نتیجه را نشان می‌دهند. در فصل پنجم نتیجه‌گیری کلی از این پژوهش ارائه خواهد شد.

فصل پنجم

نتیجه‌گیری و پیشنهادات برای تحقیقات آتی

5-1 نتیجه گیری

بازارهای مالی یک پلتفرم عالی برای سرمایه‌گذاران و معامله‌گران فراهم می‌کند تا بتوانند با هر ابزاری که به اینترنت متصل می‌شود، معامله کنند. در چند سال اخیر، مردم بیشتر جذب معاملات سهام شده‌اند. مانند هر طبقه دیگری از زندگی، بازار سهام نیز به دلیل ظهور تکنولوژی تغییر کرده است. اکنون، مردم می‌توانند سرمایه‌گذاری‌های خود را رشد دهند. تجارت آنلاین تنها نحوه خرید و فروش سهام افراد را تغییر داده است. بازارهای بودجه به سرعت پیشرفت کرده‌اند و یک بازار جهانی به هم پیوسته را تشکیل داده‌اند. این پیشرفت‌ها راه را برای فرصت‌های جدید هموار می‌کند. برخلاف چارچوب‌های مرسوم، پیش‌بینی ارزش هر سهم در بازار سهام در حال حاضر با استفاده از یادگیری ماشین، تحلیل کلان داده‌ها و یادگیری عمیق انجام می‌شود که تصمیم‌گیری بهینه‌تری را ارائه می‌دهند. بر همین اساس هدف پژوهش حاضر ارائه مدلی مبتنی بر یادگیری عمیق به منظور پیش‌بینی ارزش سهام در بازار بورس ایران بود. مدل CNN-GRU برای این هدف برگزیده شد و معیارهای ارزیابی محاسبه شده پس از اجرای این مدل نشان دادند که مدل CNN-GRU می‌تواند به خوبی ارزش سهام را پیش‌بینی نموده و تخمین بزند. نتایج این پژوهش می‌تواند به سرمایه‌گذاران و فعالان در بازارهای مالی کمک کند تا پیش‌بینی بهتری از ارزش آینده یک سهم داشته باشند و به این ترتیب سرمایه خود را هوشمندانه‌تر مدیریت نمایند.

2-5 کارهای آینده

در اینجا چند دستورالعمل آینده برای پژوهش‌های آینده پیرامون موضوع پیش‌بینی ارزش سهم در بازار سهام آمده است:

- علاوه بر استفاده از داده‌های سری زمانی برای پیش‌بینی، کاوش و استفاده از منابع داده جایگزین برای پیش‌بینی ارزش سهام مهم است. به طور خاص، بهره‌برداری از احساسات استخراج‌شده از پلتفرم‌های مختلف، مانند رسانه‌های اجتماعی و رسانه‌های خبری می‌تواند به طور قابل‌توجهی توانایی درک و پیش‌بینی دقیق حرکات بازار افزایش دهد.
- ترکیب تئوری‌های مالی مرسوم با الگوریتم‌های هوش مصنوعی مانند ترانسفورمرها، گراف پیچش و یادگیری تقویتی، منجر به بهبود عملکرد پیش‌بینی ارزش سهم در بازار سهام می‌شود.
- تحلیل بلادرنگ برای پیش‌بینی طیف وسیعی از مزایا را ارائه می‌دهد. ارائه داده‌های لحظه به لحظه، تصمیم‌گیری به‌موقع را امکان‌پذیر می‌کند و به معامله‌گران اجازه می‌دهد تا به تغییرات بازار و رویدادهای خبری سریع واکنش نشان دهند.
- با ادامه پیشرفت فناوری محاسبات کوانتومی، محققان می‌توانند کاربرد الگوریتم‌های کوانتومی را برای بهینه‌سازی استراتژی‌های معاملاتی و افزایش کارایی مدل‌های پیش‌بینی بررسی کنند.

- Babu, C. N., & Reddy, B. E. (2014). A moving-average filter based hybrid ARIMA–ANN model for forecasting time series data. *Applied Soft Computing*, 23, 27-38 .
- Beyaz, E., Tekiner, F., Zeng, X.-j., & Keane, J. (2018). Comparing technical and fundamental indicators in stock price forecasting. 2018 IEEE 20th International Conference on High Performance Computing and Communications; IEEE 16th International Conference on Smart City; IEEE 4th International Conference on Data Science and Systems (HPCC/SmartCity/DSS),
- Cabello-Solorzano, K., Ortigosa de Araujo, I., Peña, M., Correia, L., & J. Tallón-Ballesteros, A. (2023). The Impact of Data Normalization on the Accuracy of Machine Learning Algorithms: A Comparative Analysis. In P. García Bringas, H. Pérez García ,F. J. Martínez de Pisón, F. Martínez Álvarez, A. Troncoso Lora, Á. Herrero, J. L. Calvo Rolle, H. Quintián, & E. Corchado, *18th International Conference on Soft Computing Models in Industrial and Environmental Applications (SOCO 2023)* Cham.
- Chatterjee, A .,Bhowmick, H., & Sen, J. (2021). Stock price prediction using time series, econometric, machine learning, and deep learning models. 2021 IEEE Mysore Sub Section International Conference (MysuruCon) ,
- Chen, W., Zhang, H., Mehlawat, M. K., & Jia, L. (2021).(Mean–variance portfolio optimization using machine learning-based stock price prediction. *Applied Soft Computing*, 100, 106943 .
- Cho, K., Van Merriënboer, B., Bahdanau, D., & Bengio, Y. (2014). On the properties of neural machine translation: Encoder-decoder approaches. *arXiv preprint arXiv:1409.1259* .
- Dudek, G. (2023). Std: A seasonal-trend-dispersion decomposition of time series. *IEEE Transactions on Knowledge and Data Engineering* .
- Dutta, K. D., Saha, M., & Das, D. C. (2018). Determinants of P/E ratio: an empirical study on listed manufacturing companies in DSE. *International Journal of Scientific and Research Publications (IJSRP)*, 8(4), 167-174 .
- Ecer, F. (2013a). ARTIFICIAL NEURAL NETWORKS IN PREDICTING FINANCIAL PERFORMANCE: AN APPLICATION FOR TURKEY'S TOP 500 COMPANIES. *Economic Computation & Economic Cybernetics Studies & Research*, 47 .(2)
- Ecer, F. (2013b). Comparing the bank failure prediction performance of neural networks and support vector machines: The Turkish case. *Economic research-Ekonomska istraživanja*, 26(3), 81-98 .
- Elman, J. L. (1990). Finding structure in time. *Cognitive science*, 14(2), 179-211 .

- Faghfour, A., & Frish, M. (2011). Robust discrimination of human footsteps using seismic signals. *Proc SPIE*. <https://doi.org/10.1117/12.882726>
- Geertsema, P., & Lu, H. (2020). *Relative Valuation with Machine Learning*. <https://doi.org/10.13140/RG.2.2.32486.04162>
- Ghosh, B. P., Bhuiyan, M. S., Das, D., Nguyen, T. N., Jewel, R. M., Mia, M. T., Cao, D. M., & Shahid, R. (2024). Deep Learning in Stock Market Forecasting: Comparative Analysis of Neural Network Architectures Across NSE and NYSE. *Journal of Computer Science and Technology Studies*, 6(1), 68-75 .
- Ghosh, P., Neufeld, A., & Sahoo, J. K. (2022). Forecasting directional movements of stock prices for intraday trading using LSTM and random forests. *Finance Research Letters*, 46, 102280 .
- Gundoshmian, T. M ., Ardabili, S., Mosavi, A., & Várkonyi-Kóczy, A. R. (2019). Prediction of combine harvester performance using hybrid machine learning modeling and response surface methodology. *International Conference on Global Research and Education* ,
- Guo, Y., Yao, S., Cheng, H., & Zhu, W. (2020). China's copper futures market efficiency analysis: Based on nonlinear Granger causality and multifractal methods. *Resources Policy*, 68, 101716. <https://doi.org/https://doi.org/10.1016/j.resourpol.2020.101716>
- Han, C., & Fu, X .(2023) .Challenge and opportunity: deep learning-based stock price prediction by using bi-directional LSTM model. *Frontiers in Business, Economics and Management*, 8(2), 51-54 .
- Hoseinzade, E., & Haratizadeh, S. (2019). CNNpred: CNN-based stock market prediction using a diverse set of variables. *Expert Systems with Applications*, 129, 273-285 .
- Khanderwal, S., & Mohanty, D. (2021). Stock price prediction using ARIMA model. *International Journal of Marketing & Human Resource Research*, 2(2), 98-107 .
- Lai, C .Y., Chen, R.-C., & Caraka, R. E. (2019). Prediction stock price based on different index factors using LSTM. 2019 International conference on machine learning and cybernetics (ICMLC) ,
- LeCun, Y. (1989). Generalization and network design strategies. *Connectionism in perspective*, 19(143-155), 18 .
- LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11), 2278-2324 .
- Li, H., & Hu, J. (2024). A Hybrid Deep Learning Framework for Stock Price Prediction Considering the Investor Sentiment of Online Forum Enhanced by Popularity. *arXiv preprint arXiv:2405.10584* .
- Li, P., Luo, A., Liu, J., Wang, Y., Zhu, J., Deng, Y., & Zhang, J. (2020). Bidirectional Gated Recurrent Unit Neural Network for Chinese Address Element Segmentation. *ISPRS International Journal of Geo-Information*, 9(11), 635. <https://www.mdpi.com/2220-9964/9/11/635>
- Liao, S. G., Lin, Y., Kang, D. D., Chandra, D., Bon, J., Kaminski, N., Sciurba, F. C., & Tseng, G. C .(2014) .Missing value imputation in high-dimensional phenomic data: imputable or not, and how? *BMC bioinformatics*, 15, 1-12 .

- Lin, G., Lin, A., & Cao, J. (2021). Multidimensional KNN algorithm based on EEMD and complexity measures in financial time series forecasting. *Expert Systems with Applications*, 168, 114443. [https://doi.org/https://doi.org/10.1016/j.eswa.2020.114443](https://doi.org/10.1016/j.eswa.2020.114443)
- Little, R. J., & Rubin, D. B. (2019). *Statistical analysis with missing data* (Vol. 793). John Wiley & Sons .
- Liu, M., Sheng, H., Zhang ,N., Chen, Y., & Huang, L. (2022). A New Deep Network Model for Stock Price Prediction. International Conference on Machine Learning for Cyber Security ,
- Low, P., & Sakk, E. (2023). Comparison between autoregressive integrated moving average and long short term memory models for stock price prediction. *IAES International Journal of Artificial Intelligence (IJ-AI)*, 12, 1828. <https://doi.org/10.11591/ijai.v12.i4.pp1828-1835>
- Malagrino, L. S., Roman, N. T., & Monteiro, A. M. (2018). Forecasting stock market index daily direction: A Bayesian Network approach. *Expert Systems with Applications*, 105, 11-22 .
- Milosevic, N. (2016). Equity forecast: Predicting long term stock price movement using machine learning. *arXiv preprint arXiv:1603.00751* .
- Mintarya, L. N ,Halim, J. N., Angie, C., Achmad, S., & Kurniawan, A. (2023). Machine learning approaches in stock market prediction: A systematic literature review. *Procedia Computer Science*, 216, 96-102 .
- Nti, I. K., Adekoya, A. F., & Weyori, B. A. (2020). A systematic review of fundamental and technical analysis of stock market predictions. *Artificial Intelligence Review*, 53(4), 3007-3057 .
- Obeidat, S. (2021). Examining the random walk hypothesis in the Amman stock exchange: An analytical study. *Accounting*, 7(1), 137 .142-
- Patel, D., Patel, W., & Koyuncu, H. (2024). A comprehensive survey of predicting stock market prices: An analysis of traditional statistical models and machine-learning techniques. AIP Conference Proceedings ,
- Patel, J., Shah, S., Thakkar, P., & Kotecha, K. (2015). Predicting stock and stock price index movement using trend deterministic data preparation and machine learning techniques. *Expert Systems with Applications*, 42(1), 259-268 .
- Phuoc, T., Anh, P. T. K., Tam, P. H., & Nguyen, C. V. (2024). Applying machine learning algorithms to predict the stock price trend in the stock market – The case of Vietnam. *Humanities and Social Sciences Communications*, 11(1), 393. <https://doi.org/10.1057/s41599-024-02807-x>
- Prasad, V. K., Savaliya, D., Sanghavi, S ,Sakariya, V., Bhattacharya, P., Verma, J. P., Shah, R., & Tanwar, S. (2022). Stock Price Prediction for Market Forecasting Using Machine Learning Analysis. International Conference on Computing, Communications, and Cyber-Security ,
- Qin, L., Yu, N., & Zhao, D. (2018). Applying the convolutional neural network deep learning technology to behavioural recognition in intelligent video. *Tehnički vjesnik*, 25(2), 528-535 .
- Rezaei, H., Faaljou, H., & Mansourfar, G. (2021). Stock price prediction using deep learning and frequency decomposition. *Expert Systems with Applications*, 169, 114332 .


- Rouf, N., Malik, M. B., Arif, T., Sharma, S., Singh, S., Aich, S., & Kim, H.-C. (2021). Stock market prediction using machine learning techniques: a decade survey on methodologies, recent developments, and future directions. *Electronics*, 10(21), 2717 .
- Salemi Mottaghi, M., & Haghir Chehrehghani, M. (2023). A deep comprehensive model for stock price prediction. *Journal of Ambient Intelligence and Humanized Computing*, 14(8), 11 .11395-385<https://doi.org/10.1007/s12652-023-04653-2>
- Sen, J., Mehtab, S., & Dutta, A. (2023). Stock Price Prediction Using Machine Learning and LSTM-Based Deep Learning Models. *Authorea Preprints* .
- Sen, J., Mehtab, S., & Nath, G. (2023). Stock price prediction using deep learning models. *Authorea Preprints* .
- Seun, E., & Olawunmi Asake, A. (2024). Stock Price Prediction: Evaluating The Efficacy Of CNN, LSTM, CNN-LSTM, and CNN-BILSTM Models. *International Journal of Computing and Digital Systems*, 16(1), 1 .10-
- Sharma, N., Sharma, R., & Jindal, N. (2021). Machine Learning and Deep Learning Applications-A Vision. *Global Transitions Proceedings*, 2(1), 24-28. <https://doi.org/https://doi.org/10.1016/j.gltp.2021.01.004>
- Sit, M., Demiray, B., Xiang, Z., Ewing, G ., Sermet, Y., & Demir, I. (2020). A Comprehensive Review of Deep Learning Applications in Hydrology and Water Resources. <https://doi.org/10.31223/osf.io/xs36g>
- Sonkavde, G., Dharrao, D. S., Bongale, A. M., Deokate, S. T., Doreswamy, D., & Bhat, S. K. (2023). Forecasting Stock Market Prices Using Machine Learning and Deep Learning Models: A Systematic Review, Performance Analysis and Discussion of Implications. *International Journal of Financial Studies*, 11(3), 94. <https://www.mdpi.com/2227-7072/11/3/94>
- Syukur, A., & Istiawan, D. (2021). Prediction of LQ45 Index in Indonesia Stock Exchange: A Comparative Study of Machine Learning Techniques. *International Journal of Intelligent Engineering & Systems*, 14 .(1)
- Vuong, P. H., Phu, L. H., Van Nguyen, T. H., Duy, L. N., Bao, P. T., & Trinh, T. D. (2024). A bibliometric literature review of stock price forecasting: From statistical model to deep learning approach. *Science Progress*, 107(1), 00368504241236557. <https://doi.org/10.1177/00368504241236557>
- Wu, J. M.-T., Li, Z., Herencsar, N., Vo, B., & Lin, J. C.-W. (2023). A graph-based CNN-LSTM stock price prediction algorithm with leading indicators. *Multimedia Systems*, 29(3), 1751-1770. <https://doi.org/10.1007/s00530-021-00758-w>
- Xu, Y., Chhim, L., Zheng, B., & Nojima, Y. (2020). Stacked deep learning structure with bidirectional long-short term memory for stock market prediction. Neural Computing for Advanced Applications: First International Conference, NCAA 2020, Shenzhen, China, July 3–5, 2020, Proceedings 1 ,
- Yunneng, Q. (2020). A new stock price prediction model based on improved KNN. 2020 7th International Conference on Information Science and Control Engineering (ICISCE) ,
- Zhang, L., Wang, S., & Liu, B. (2018). Deep learning for sentiment analysis: A survey. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, 8(4), e1253 .

- Zhang, R., Tian, Z., McCarthy, K. J., Wang, X., & Zhang, K. (2023). Application of machine learning techniques to predict entrepreneurial firm valuation. *Journal of Forecasting*, 42(2), 402-417 .
- Zhou, & Chellappa. (1988). Computation of optical flow using a neural network. IEEE 1988 international conference on neural networks ,
- Zhou, Y., Aryal, S., & Bouadjenek, M. R. (2024). Review for Handling Missing Data with special missing mechanism. *arXiv preprint arXiv:2404.04905* .

Abstract

The stock market is considered one of the most complex systems comprising many components and its price goes up and down without any clear pattern. With the constant increase in market value, stock trading has become the investment center for many financial investors. The stock market is a key axis in any growing and prosperous economy, and every investment in the market is related to maximizing profit and minimizing risk. Many analysts and researchers have developed tools and methods that predict the movement of stock prices and values and help investors make the right decisions. Advanced trading models enable researchers to predict the market using data from social platforms. The use of advanced methods has greatly increased the accuracy of forecasting. Meanwhile, the analysis and forecasting of stock markets is still one of the most challenging fields of study due to the presence of dynamic, irregular, and chaotic data. This research aims to provide a model that can predict the stock value. For this purpose, the CNN-GRU model has been used to predict the stock value of ten companies. The results of this research are useful for financial market policymakers as an indicator that they can use to improve their forecast.

Keywords: Deep learning, Convolutional neural network, Gated regression unit, CNN-GRU, Stock value prediction.



**K.N. Toosi University of Technology
Department of Industrial Engineering**

Developing a Stock Valuation Model Using Machine Learning

Kourosh Mollaghadi

Supervisor:

Dr.Amir Abbas Najafi

Advisor:

Dr.Majid Mirzaii

A Thesis Presented in Partial Fulfillment of the Requirements for the Degree of Master of
Science in Financial Engineering

July 2024